

# Linear Model (一元)

## TOC

- [🔗](#) TOC
- [🔗](#) 基本内容
  - [🔗](#) Assumption
  - [🔗](#) Estimates of  $(\alpha, \beta)$
- [🔗](#) We can get estimates by 3 ways: LSE, BLUE, MLE
  - [🔗](#) LSE 最小二乘法
  - [🔗](#) BLUE 最佳无偏法
    - [🔗](#) 对  $\hat{\beta}$  的线性无偏估计推导
    - [🔗](#) 对  $\hat{\alpha}$  的 BLUE 推导
      - [🔗](#) 最小方差的目标转化
      - [🔗](#) 拉格朗日法求最优  $c$
  - [🔗](#) 极大似然估计 (MLE) : 加入对  $\sigma^2$  的估计
    - [🔗](#) 一、 $\alpha, \beta$  的极大似然估计
    - [🔗](#) 二、 $\sigma^2$  的极大似然估计与无偏修正
      - [🔗](#)  $\sigma^2$  的 MLE
      - [🔗](#) 1.3.2.2 偏差分析与无偏估计
- [🔗](#) 估计量的性质
  - [🔗](#)  $\hat{\beta}$
  - [🔗](#)  $2\hat{\alpha}$ 
    - [🔗](#) 联合正态分布(joint distribution)
  - [🔗](#) 残差与估计量的独立性及卡方分布
    - [🔗](#) proof:  $\begin{bmatrix} \hat{\alpha} \\ \hat{\beta} \end{bmatrix} \perp\!\!\!\perp s^2$
    - [🔗](#) proof:  $(n-2)s^2 \sim \sigma^2 \chi^2(n-2)$ 
      - [🔗](#) proof:

- [🔗 proof](#)

- [🔗](#) sum of squares

- [🔗](#) Total sum of squares (SST)
- [🔗](#) Regression sum of squares (SSR)
- [🔗](#) Residual sum of squares (SSE)
- [🔗](#) 均方 (Mean Square)
- [🔗](#)  $SST = SSR + SSE$
- [🔗](#) 判定系数  $r^2$ 
  - [🔗](#) 意义分析

- [🔗](#) Hypothesis Testing

- [🔗](#) 检验假设
- [🔗](#) 假设  $H_0$  下的平方和分布
  - [🔗](#) 总平方和 (SST)  $SST \sim \sigma^2 \chi^2(n-1)$ .
  - [🔗](#) 回归平方和 (SSR)  $SSR \sim \sigma^2 \chi^2(1)$
  - [🔗](#) 残差平方和 (SSE)
- [🔗](#) 基于  $F$  统计量的检验
- [🔗](#) 基于  $t$  统计量的检验
  - [🔗](#)  $H_0$  成立时  $\hat{\beta}$  的分布
  - [🔗](#) 统计量推导
  - [🔗](#) 决策规则
- [🔗](#) remark ( $F$  与  $t$  的等价性) :

- [🔗](#) 置信区间 (CI: Confidence Interval)

- [🔗](#) 回归系数  $\beta$  的置信区间
  - [🔗](#) 统计量分布
  - [🔗](#) 置信区间推导
- [🔗](#) 均值  $\mu_0 = \alpha + \beta x_0$  的置信区间 (mean response)
  - [🔗](#) 统计量分布
  - [🔗](#) 置信区间推导
- [🔗](#) 个体预测值  $y_{n+1} = \alpha + \beta x_{n+1} + \varepsilon_{n+1}$  的置信区间 (预测区间)

- [🔗](#) 统计量分布
- [🔗](#) 置信区间（预测区间）推导

## 基本内容

### Assumption

1.  $Y = \alpha + \beta x + \varepsilon$ 
  - $\alpha$ : Intercept (回归直线在纵轴的截距, 反映  $x = 0$  时  $Y$  的期望水平)
  - $\beta$ : Slope ( $x$  每变化 1 单位,  $Y$  的平均变化量, 体现  $x$  对  $Y$  的影响强度与方向)  
( $\alpha, \beta$  为模型待估参数)
  - $x$ : Independent variable (自变量, 可为给定的固定值, 也可某随机变量的观测值, 如“温度”“时间”等)
  - $\varepsilon$ : Random Error Term (随机误差项)
    - $E\varepsilon = 0 / E(\varepsilon|x) = 0$ : 误差的期望为 0, 说明模型已捕获  $x$  对  $Y$  的系统性影响, 剩余波动无偏向性
    - $\text{Var}\varepsilon = \sigma^2 / \text{Var}(\varepsilon|x) = \sigma^2$ : 误差的方差恒定 (同方差性), 即无论  $x$  取何值, 误差波动幅度稳定,  $\sigma^2$  为待估参数
2. Observation  $(x_1, Y_1) \dots (x_n, Y_n)$  (从总体中抽取的  $n$  组样本观测值)
  - $(\varepsilon_i)$  – uncorrelated (不同观测的误差项之间无线性关联, 若违背则 OLS 估计有效性下降, 如时间序列中误差的“自相关”)
  - $(Y_i)$  – uncorrelated (因变量的不同观测之间无线性关联, 由“ $\varepsilon_i$  不相关”和模型线性结构推导而来)
  - $E(Y_i) = \alpha + \beta x_i$  ( $Y_i$  的期望由  $\alpha + \beta x_i$  系统性决定)
  - $\text{Var}(Y) = \text{Var}(\varepsilon)$  ( $Y$  的波动完全源于误差项  $\varepsilon$  的波动)

### Estimates of $(\alpha, \beta)$

- **Notation**
  - Sample var of  $x$ :

$$\frac{1}{n} \sum (x_i - \bar{x})^2 \triangleq \frac{s_{xx}}{n}$$

( $s_{xx} = \sum (x_i - \bar{x})^2$  是  $x$  离均差平方和, 反映  $x$  的样本波动程度)

- Cov of  $(x, Y)$ :

$$\frac{1}{n} \sum (x_i - \bar{x})(Y_i - \bar{Y}) = \frac{s_{xy}}{n}$$

( $s_{xy} = \sum (x_i - \bar{x})(Y_i - \bar{Y})$  是  $x$  与  $Y$  的离均差乘积和, 反映二者的线性关联程度)

- We want to get

- $(\hat{\alpha}, \hat{\beta})$ : Estimates of  $(\alpha, \beta)$
- $\hat{\mu}(x) = \hat{\alpha} + \hat{\beta}x$ : Fitted regression line
- $\hat{y}_i = \hat{\alpha} + \hat{\beta}x_i$ : Fitted value
- $e_i = y_i - \hat{y}_i$ : Residual

---

## We can get estimates by 3 ways: LSE, BLUE, MLE

---

### LSE 最小二乘法

---

- Residual Sum of Squares (RRS)

关于直线  $E(Y|x) = \beta x + \alpha$

$$\text{RRS}(\alpha, \beta) = \sum_{i=1}^n (y_i - \beta x_i - \alpha)^2 = \|y - \beta x - \alpha \mathbf{1}_n\|_2^2$$

因  $\text{RRS}(\alpha, \beta)$  关于  $(\alpha, \beta)$  均为凸, 故对  $(\alpha, \beta)$  求偏导并令其为 0:

$$\begin{cases} \frac{\partial \text{RRS}}{\partial \alpha} = -2 \mathbf{1}_n^T (y - \beta x - \alpha \mathbf{1}_n) = 0 \\ \frac{\partial \text{RRS}}{\partial \beta} = -2 x^T (y - \beta x - \alpha \mathbf{1}_n) = 0 \end{cases}$$

- 求解  $(\hat{\alpha}, \hat{\beta})$

展开偏导方程:

$$\begin{cases} \mathbf{1}_n^T(y - \beta x - \alpha \mathbf{1}_n) = n\bar{y} - \beta n\bar{x} - n\alpha = 0 \\ x^T(y - \beta x - \alpha \mathbf{1}_n) = x^T y - \beta x^T x - n\alpha \bar{x} = 0 \end{cases}$$

由第一个方程得  $\alpha = \bar{y} - \beta \bar{x}$ ，代入第二个方程：

$$x^T y - \beta x^T x - n(\bar{y} - \beta \bar{x})\bar{x} = 0$$

整理得：

$$\hat{\beta} = \frac{x^T y - n\bar{x}\bar{y}}{x^T x - n\bar{x}^2}, \quad \hat{\alpha} = \bar{y} - \hat{\beta}\bar{x}$$

## BLUE 最佳无偏法

在线性模型中，我们希望估计量  $\hat{\beta}, \hat{\alpha}$  是**线性的**（即能表示为  $y$  的线性组合  $c^T y$ ），且是**无偏的**（即  $E(\hat{\theta}) = \theta$ ， $\theta$  代表待估参数  $\beta$  或  $\alpha$ ）。

### 对 $\hat{\beta}$ 的线性无偏估计推导

令  $\hat{\beta} = c^T y$ ，其中

$y = \alpha \mathbf{1}_n + \beta x + \varepsilon$ （ $\mathbf{1}_n$  为全1向量， $\varepsilon$  为误差向量）。

- 求期望：

$$\begin{aligned} E(\hat{\beta}) &= E(c^T y) = E(c^T (\alpha \mathbf{1}_n + \beta x + \varepsilon)) \\ &= \alpha \mathbf{1}_n^T c + \beta x^T c \quad (E(\varepsilon) = 0) \end{aligned}$$

- 无偏性要求  $E(\hat{\beta}) = \beta$ ，因此必须满足：

$$\begin{cases} \mathbf{1}_n^T c = 0 & \text{(消去 } \alpha \text{ 的影响)} \\ x^T c = 1 & \text{(保证 } \beta \text{ 系数为1)} \end{cases}$$

最小方差的优化目标

线性估计的方差为：

$$\text{Var}(\hat{\beta}) = \text{Var}(c^T y) = c^T (\sigma^2 I_n) c = \sigma^2 \|c\|_2^2.$$

目标：在满足无偏性约束  $\mathbf{1}_n^T c = 0$ ,  $x^T c = 1$  下, 最小化  $\|c\|_2^2$ 。

**拉格朗日对偶法求解最优  $c$**

构造拉格朗日函数：

$$\mathcal{L} = \|c\|_2^2 + \lambda_1(\mathbf{1}_n^T c) + \lambda_2(x^T c - 1)$$

对  $c$  求偏导：

$$\frac{\partial \mathcal{L}}{\partial c} = 2c + \lambda_1 \mathbf{1}_n + \lambda_2 x = 0 \quad (1)$$

结合无偏性约束：

$$\begin{cases} \mathbf{1}_n^T c = 0 & (2) \\ x^T c = 1 & (3) \end{cases}$$

**(1) 左乘  $\mathbf{1}_n^T$**

$$2\mathbf{1}_n^T c + \lambda_1 n + \lambda_2 n \bar{x} = 0$$

代入  $\mathbf{1}_n^T c = 0$ ：

$$\lambda_1 = -\lambda_2 \bar{x} \quad (4)$$

**(2) 左乘  $x^T$**

$$2x^T c + \lambda_1 n \bar{x} + \lambda_2 x^T x = 0$$

代入  $x^T c = 1$  和 (4)：

$$2 - \lambda_2 \bar{x} n \bar{x} + \lambda_2 x^T x = 0$$

整理得：

$$\lambda_2 = -\frac{2}{x^T x - n\bar{x}^2}, \quad \lambda_1 = \frac{2\bar{x}}{x^T x - n\bar{x}^2}.$$

所以最终得到  $c$

$$\hat{c} = -\frac{1}{2}(\lambda_1 \mathbf{1}_n + \lambda_2 x) = \frac{-\bar{x} \mathbf{1}_n + x}{x^T x - n\bar{x}^2}.$$

代入  $\hat{\beta} = c^T y$ :

$$\hat{\beta} = \frac{x^T y - n\bar{x}\bar{y}}{x^T x - n\bar{x}^2} = \frac{s_{xy}}{s_{xx}}.$$

方差:

$$\text{Var}(\hat{\beta}) = \frac{\sigma^2}{s_{xx}}.$$

## 对 $\hat{\alpha}$ 的 BLUE 推导

### 线性估计与无偏性要求

令  $\hat{\alpha} = c^T y$  ( $c$  为待求系数向量), 其中  
 $y = \alpha \mathbf{1}_n + \beta x + \varepsilon$  ( $\mathbf{1}_n$  为全1向量,  $\varepsilon$  为误差向量)。

- 求期望:

$$\begin{aligned} E(\hat{\alpha}) &= E(c^T y) = E[c^T (\alpha \mathbf{1}_n + \beta x + \varepsilon)] \\ &= \alpha \mathbf{1}_n^T c + \beta x^T c \quad (\text{因 } E(\varepsilon) = 0) \end{aligned}$$

- 无偏性要求  $E(\hat{\alpha}) = \alpha$ , 因此约束为:

$$\begin{cases} \mathbf{1}_n^T c = 1 \\ x^T c = 0 \end{cases}$$

即: 估计量对  $\alpha$  的系数为 1, 对  $\beta$  的影响为 0。

### 最小方差的目标转化

由于

$$\text{Var}(y) = \sigma^2 I_n$$

故线性估计量方差为：

$$\text{Var}(\hat{\alpha}) = c^T (\sigma^2 I_n) c = \sigma^2 \|c\|_2^2.$$

目标：在约束

$$\mathbf{1}_n^T c = 1, \quad x^T c = 0$$

下最小化  $\|c\|_2^2$ 。

### 拉格朗日法求最优 $c$

构造拉格朗日函数：

$$\mathcal{L} = \|c\|_2^2 + \lambda_1 (\mathbf{1}_n^T c - 1) + \lambda_2 (x^T c)$$

对  $c$  求偏导并令其为零：

$$2c + \lambda_1 \mathbf{1}_n + \lambda_2 x = 0. \quad (1)$$

结合约束条件：

$$\begin{cases} \mathbf{1}_n^T c = 1 & (2) \\ x^T c = 0 & (3) \end{cases}$$

(1) 左乘  $\mathbf{1}_n^T$  得：

$$2\mathbf{1}_n^T c + \lambda_1 n + \lambda_2 n\bar{x} = 0.$$

利用  $\mathbf{1}_n^T c = 1$ ：

$$2 + n\lambda_1 + n\lambda_2\bar{x} = 0. \quad (4)$$



(2) 左乘  $x^T$  得:

$$2x^T c + \lambda_1 n \bar{x} + \lambda_2 x^T x = 0.$$

利用  $x^T c = 0$ :

$$n\lambda_1 \bar{x} + \lambda_2 x^T x = 0. \quad (5)$$

解线性方程组 (4)-(5)

由 (4):

$$\lambda_1 = -\frac{2 + n\lambda_2 \bar{x}}{n}.$$

代入 (5):

$$n\bar{x} \left( -\frac{2 + n\lambda_2 \bar{x}}{n} \right) + \lambda_2 x^T x = 0$$

化简:

$$-2\bar{x} - n\lambda_2 \bar{x}^2 + \lambda_2 x^T x = 0$$

令  $s_{xx} = x^T x - n\bar{x}^2$ , 解得:

$$\lambda_2 = \frac{2\bar{x}}{s_{xx}}.$$

代回 (4) 得:

$$\lambda_1 = -\frac{2x^T x}{ns_{xx}}.$$

$$\hat{c} = -\frac{1}{2}(\lambda_1 \mathbf{1}_n + \lambda_2 x) = \frac{x^T x \mathbf{1}_n - n\bar{x} x}{ns_{xx}}.$$

利用

$$\hat{\alpha} = \hat{c}^T y, \quad x^T y = n\bar{x}\bar{y} + s_{xy}, \quad s_{xx} = x^T x - n\bar{x}^2,$$

代入得：

$$\begin{aligned} \hat{\alpha} &= \frac{x^T x \cdot n\bar{y} - n\bar{x}(n\bar{x}\bar{y} + s_{xy})}{ns_{xx}} \\ &= \frac{\bar{y}(x^T x - n\bar{x}^2) - \bar{x}s_{xy}}{s_{xx}} \\ &= \bar{y} - \bar{x} \frac{s_{xy}}{s_{xx}} \\ &= \bar{y} - \hat{\beta}\bar{x}. \end{aligned}$$

即：

$$\hat{\alpha} = \bar{y} - \hat{\beta}\bar{x}.$$

$$\text{Var}(\hat{\alpha}) = \sigma^2 \|\hat{c}\|_2^2.$$

带入  $\hat{c} = \frac{x^T x \mathbf{1}_n - n\bar{x}x}{ns_{xx}}$  得：

$$\text{Var}(\hat{\alpha}) = \frac{\sigma^2 x^T x}{ns_{xx}}.$$

所以

- $\hat{\alpha} = \bar{y} - \hat{\beta}\bar{x}$   
是满足无偏性的**线性估计量**中方差最小者，即 BLUE。
- 它与最小二乘法 LSE 得到的截距完全一致。
- 方差：

$$\text{Var}(\hat{\alpha}) = \frac{\sigma^2 x^T x}{n(x^T x - n\bar{x}^2)}.$$

---

## 极大似然估计 (MLE)：加入对 $\sigma^2$ 的估计

---

## 一、 $\alpha, \beta$ 的极大似然估计

假设线性模型为  $Y = \alpha \mathbf{1}_n + \beta x + \varepsilon$ , 其中  $\varepsilon \sim N(0, \sigma^2 I_n)$  (即误差服从正态分布), 则

$$Y \sim N(\alpha \mathbf{1}_n + \beta x, \sigma^2 I_n).$$

### 似然函数与对数似然函数

联合概率密度 (似然函数) 为:

$$L(\alpha, \beta, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(y_i - \alpha - \beta x_i)^2}{2\sigma^2}\right\} = \frac{1}{(2\pi)^{n/2}(\sigma^2)^{n/2}} \exp\left\{-\frac{1}{2\sigma^2}\|y - \alpha \mathbf{1}_n - \beta x\|_2^2\right\}.$$

取对数得对数似然函数:

$$\ell(\alpha, \beta, \sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \|y - \alpha \mathbf{1}_n - \beta x\|_2^2.$$

### 对 $\alpha, \beta$ 的极大化

最大化  $\ell(\alpha, \beta, \sigma^2)$  关于  $\alpha, \beta$  的部分, 等价于最小化残差平方和:

$$\text{RSS}(\alpha, \beta) = \|y - \alpha \mathbf{1}_n - \beta x\|_2^2 = \sum_{i=1}^n (y_i - \alpha - \beta x_i)^2.$$

这与**最小二乘法 (LSE)** 的目标完全一致, 因此:

$$(\hat{\alpha}, \hat{\beta})_{\text{MLE}} = (\hat{\alpha}, \hat{\beta})_{\text{LSE}} = \left( \bar{y} - \hat{\beta} \bar{x}, \frac{s_{xy}}{s_{xx}} \right),$$

其中

$$s_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2, \quad s_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}), \quad \bar{x} = \frac{1}{n} \sum x_i, \quad \bar{y} = \frac{1}{n} \sum y_i.$$

## 二、 $\sigma^2$ 的极大似然估计与无偏修正

### $\sigma^2$ 的 MLE

对对数似然函数关于  $\sigma^2$  求偏导并令其为 0:

$$\frac{\partial \ell}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \|y - \alpha \mathbf{1}_n - \beta x\|_2^2 = 0.$$

代入  $\hat{\alpha}, \hat{\beta}$ , 解得:

$$\hat{\sigma}_{\text{MLE}}^2 = \frac{1}{n} \|y - \hat{\alpha} \mathbf{1}_n - \hat{\beta} x\|_2^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2,$$

其中  $\hat{y}_i = \hat{\alpha} + \hat{\beta} x_i$  为拟合值。

### 1.3.2.2 偏差分析与无偏估计

计算  $\hat{\sigma}_{\text{MLE}}^2$  的期望:

$$E(\hat{\sigma}_{\text{MLE}}^2) = E\left(\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2\right).$$

利用  $\text{Var}(y_i) = \sigma^2$  和  $\text{Var}(\hat{y}_i) = \text{Var}(\hat{\alpha} + \hat{\beta} x_i) = \frac{\sigma^2}{n} + \frac{(x_i - \bar{x})^2}{s_{xx}} \sigma^2$ , 推导得:

$$E(\hat{\sigma}_{\text{MLE}}^2) = \frac{n-2}{n} \sigma^2.$$

为得到无偏估计, 对其修正:

$$s^2 = \frac{n}{n-2} \hat{\sigma}_{\text{MLE}}^2 = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{y}_i)^2.$$

此时  $E(s^2) = \sigma^2$ , 即  $s^2$  是  $\sigma^2$  的无偏估计。

## 估计量的性质

---

$\hat{\beta}$

---

$$\begin{aligned}
\hat{\beta} &= \frac{s_{xy}}{s_{xx}} = \frac{x^T y - n\bar{x}\bar{y}}{s_{xx}} = \frac{x^T y - \bar{x}\mathbf{1}_n^T y}{s_{xx}} = \frac{(x^T - \bar{x}\mathbf{1}_n^T)y}{s_{xx}} \\
&= \frac{(x^T - \bar{x}\mathbf{1}_n^T)(\alpha\mathbf{1}_n + \beta x + \varepsilon)}{s_{xx}} \\
&= \frac{1}{s_{xx}} [(x^T - \bar{x}\mathbf{1}_n^T)\alpha\mathbf{1}_n + (x^T - \bar{x}\mathbf{1}_n^T)\beta x + (x^T - \bar{x}\mathbf{1}_n^T)\varepsilon] \\
&= \frac{1}{s_{xx}} [n\alpha\bar{x} - \alpha\bar{x}n + \beta x^T x - \beta n\bar{x}^2 + (x^T - \bar{x}\mathbf{1}_n^T)\varepsilon] \\
&= \frac{1}{s_{xx}} [\beta s_{xx} + (x^T - \bar{x}\mathbf{1}_n^T)\varepsilon] \\
&= \beta + \frac{x^T - \bar{x}\mathbf{1}_n^T}{s_{xx}} \varepsilon
\end{aligned}$$

- **无偏性:**  $E(\hat{\beta}) = \beta + \frac{x^T - \bar{x}\mathbf{1}_n^T}{s_{xx}} E(\varepsilon) = \beta$  (因  $E(\varepsilon) = 0$ ) .
- **方差:**

$$\text{Var}(\hat{\beta}) = \frac{(x^T - \bar{x}\mathbf{1}_n^T)(x - \bar{x}\mathbf{1}_n)}{s_{xx}^2} \sigma^2 = \frac{\sigma^2}{s_{xx}}$$

## 2 $\hat{\alpha}$

---

$$\begin{aligned}
\hat{\alpha} &= \bar{y} - \hat{\beta}\bar{x} = \frac{1}{n}\mathbf{1}_n^T y - \bar{x} \left( \beta + \frac{x^T - \bar{x}\mathbf{1}_n^T}{s_{xx}} \varepsilon \right) \\
&= \frac{1}{n}\mathbf{1}_n^T (\alpha\mathbf{1}_n + \beta x + \varepsilon) - \beta\bar{x} - \frac{\bar{x}(x^T - \bar{x}\mathbf{1}_n^T)}{s_{xx}} \varepsilon \\
&= \alpha + \beta\bar{x} + \frac{1}{n}\mathbf{1}_n^T \varepsilon - \beta\bar{x} - \frac{\bar{x}x^T - \bar{x}^2\mathbf{1}_n^T}{s_{xx}} \varepsilon \\
&= \alpha + \left( \frac{1}{n}\mathbf{1}_n^T - \frac{\bar{x}x^T - \bar{x}^2\mathbf{1}_n^T}{s_{xx}} \right) \varepsilon
\end{aligned}$$

- **无偏性:**  $E(\hat{\alpha}) = \alpha$ .
- **方差:**

$$\begin{aligned}
\text{Var}(\hat{\alpha}) &= \left( \frac{1}{n} \mathbf{1}_n^T - \frac{\bar{x} \mathbf{x}^T - \bar{x}^2 \mathbf{1}_n^T}{s_{xx}} \right) \sigma^2 I_n \left( \frac{1}{n} \mathbf{1}_n - \frac{x \bar{x} - \bar{x}^2 \mathbf{1}_n}{s_{xx}} \right) \\
&= \sigma^2 \left( \frac{1}{n} + \frac{\bar{x}^2 s_{xx}}{s_{xx}^2} \right) \\
&= \sigma^2 \left( \frac{1}{n} + \frac{\bar{x}^2}{s_{xx}} \right)
\end{aligned}$$

$\hat{\alpha}$  与  $\hat{\beta}$  的协方差

$$\begin{aligned}
\text{Cov}(\hat{\alpha}, \hat{\beta}) &= \text{Cov} \left( \alpha + \left( \frac{1}{n} \mathbf{1}_n^T - \frac{\bar{x} \mathbf{x}^T - \bar{x}^2 \mathbf{1}_n^T}{s_{xx}} \right) \varepsilon, \beta + \frac{x^T - \bar{x} \mathbf{1}_n^T}{s_{xx}} \varepsilon \right) \\
&= \left( \frac{1}{n} \mathbf{1}_n^T - \frac{\bar{x} \mathbf{x}^T - \bar{x}^2 \mathbf{1}_n^T}{s_{xx}} \right) \sigma^2 I_n \frac{x - \bar{x} \mathbf{1}_n}{s_{xx}} \\
&= -\frac{\bar{x} \sigma^2}{s_{xx}}
\end{aligned}$$

## 联合正态分布(joint distribution)

已知  $\varepsilon \sim N(0, \sigma^2 I_n)$ , 且  $\hat{\alpha}, \hat{\beta}$  是  $\varepsilon$  的线性组合, 故

$$\begin{bmatrix} \hat{\alpha} \\ \hat{\beta} \end{bmatrix} \sim N \left( \begin{bmatrix} \alpha \\ \beta \end{bmatrix}, \sigma^2 \begin{bmatrix} \frac{1}{n} + \frac{\bar{x}^2}{s_{xx}} & -\frac{\bar{x}}{s_{xx}} \\ -\frac{\bar{x}}{s_{xx}} & \frac{1}{s_{xx}} \end{bmatrix} \right)$$

## 残差与估计量的独立性及卡方分布

- $(n-2)s^2 \sim \sigma^2 \chi^2(n-2)$
- $\begin{bmatrix} \hat{\alpha} \\ \hat{\beta} \end{bmatrix} \perp\!\!\!\perp s^2$

$$(n-2)s^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = e_1^2 + e_2^2 + \cdots + e_n^2$$

其中  $e_i = y_i - \hat{y}_i$  为残差。

**proof:**  $\begin{bmatrix} \hat{\alpha} \\ \hat{\beta} \end{bmatrix} \perp\!\!\!\perp s^2$

$$(n-2)s^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = e_1^2 + e_2^2 + \cdots + e_n^2$$

证明  $\begin{bmatrix} \hat{\alpha} \\ \hat{\beta} \end{bmatrix} \perp\!\!\!\perp s^2$ , 只需证  $e_j \perp\!\!\!\perp \begin{bmatrix} \hat{\alpha} \\ \hat{\beta} \end{bmatrix}$  ( $j = 1 \rightarrow n$ )

对残差  $e_j$  展开:

$$\begin{aligned} e_j &= y_j - \hat{y}_j = y_j - (\hat{\alpha} + \hat{\beta}x_j) \\ &= \sum_{i=1}^n y_i \delta_{ij} - \left( \frac{1}{n} \sum_{i=1}^n y_i + \frac{(x_i - \bar{x})(x_j - \bar{x})}{s_{xx}} \sum_{i=1}^n y_i \right) \\ &= \sum_{i=1}^n \left[ \delta_{ij} - \frac{1}{n} - \frac{(x_i - \bar{x})(x_j - \bar{x})}{s_{xx}} \right] y_i \end{aligned}$$

因  $\begin{bmatrix} \hat{\alpha} \\ \hat{\beta} \end{bmatrix}$  是  $y$  的线性组合, 且  $y \sim N(*, *)$ , 故  $\begin{bmatrix} \hat{\alpha} \\ \hat{\beta} \\ e_j \end{bmatrix}$  服从**联合正态分布**。

**协方差为0的推导 (以  $\text{Cov}(\hat{\beta}, e_j)$  为例)**

$$\begin{aligned} \text{Cov}(\hat{\beta}, e_j) &= \text{Cov} \left( \sum_{i=1}^n \frac{x_i - \bar{x}}{s_{xx}} y_i, \sum_{i=1}^n \left[ \delta_{ij} - \frac{1}{n} - \frac{(x_i - \bar{x})(x_j - \bar{x})}{s_{xx}} \right] y_i \right) \\ &= \sum_{i=1}^n \frac{x_i - \bar{x}}{s_{xx}} \left( \delta_{ij} - \frac{1}{n} - \frac{(x_i - \bar{x})(x_j - \bar{x})}{s_{xx}} \right) \sigma^2 \\ &= \left[ \frac{x_j - \bar{x}}{s_{xx}} - \frac{x_j - \bar{x}}{s_{xx}} \cdot \frac{1}{s_{xx}} \sum_{i=1}^n (x_i - \bar{x})^2 \right] \sigma^2 \\ &= \left[ \frac{x_j - \bar{x}}{s_{xx}} - \frac{x_j - \bar{x}}{s_{xx}} \right] \sigma^2 = 0 \end{aligned}$$

同理可证  $\text{Cov}(\hat{\alpha}, e_j) = 0$ 。

因联合正态分布中“协方差为0等价于独立”, 故每个  $e_j$  均独立于  $\begin{bmatrix} \hat{\alpha} \\ \hat{\beta} \end{bmatrix}$ 。

因此,

$$(n-2)s^2 = \sum_{i=1}^n e_i^2 \quad \text{独立于} \quad \begin{bmatrix} \hat{\alpha} \\ \hat{\beta} \end{bmatrix}$$

**proof:**  $(n-2)s^2 \sim \sigma^2 \chi^2(n-2)$

证明这个结论之前我们先证明一个基础的

单变量正态样本的方差卡方分布与独立性（基础结论）

若  $X_1, X_2, \dots, X_n \stackrel{iid}{\sim} N(\mu, \sigma^2)$ , 令

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2,$$

则有以下结论：

1.  $(n-1)s^2 \sim \sigma^2 \chi^2(n-1)$
2.  $s^2 \perp \bar{X}$

**proof:**

令  $Z_i = X_i - \bar{X}$ , 则  $E(Z_i) = 0$ 。

构造向量

$$Z = \begin{bmatrix} Z_1 \\ Z_2 \\ \vdots \\ Z_n \end{bmatrix}, \quad F = \begin{bmatrix} X_1 - \mu \\ X_2 - \mu \\ \vdots \\ X_n - \mu \end{bmatrix}.$$

因为  $X_i \sim N(\mu, \sigma^2)$ , 所以  $F \sim N(0, \sigma^2 I_n)$ 。

由  $\bar{X} = \mu + \bar{F}$  (其中  $\bar{F} = \frac{1}{n} \sum_{i=1}^n F_i \sim N(0, \frac{\sigma^2}{n})$ ) , 可得:

$$Z = F - \bar{F} \mathbf{1}_n = F - \frac{\mathbf{1}_n \mathbf{1}_n^T}{n} F = \left( I_n - \frac{\mathbf{1}_n \mathbf{1}_n^T}{n} \right) F$$

令



$$A = I_n - \frac{\mathbf{1}_n \mathbf{1}_n^T}{n},$$

则  $A$  是**对称幂等矩阵** ( $A^T = A$ ,  $A^2 = A$ ) 。

- 迹:  $\text{tr}(A) = \text{tr}(I_n) - \text{tr}\left(\frac{\mathbf{1}_n \mathbf{1}_n^T}{n}\right) = n - 1$
- 特征值: 对称幂等矩阵的特征值仅为0或1, 且非零特征值的个数等于迹, 故  $A$  有  $n - 1$  个特征值1, 1个特征值0。

对  $A$  进行正交特征分解  $A = Q^T \Lambda Q$  ( $\Lambda$  为对角矩阵, 对角元为特征值) , 则:

$$Z^T Z = F^T A^T A F = F^T A F = (QF)^T \Lambda (QF)$$

因为  $QF \sim N(0, \sigma^2 I_n)$ , 故

$$(n-1)s^2 = Z^T Z = \sigma^2 \sum_{i=1}^{n-1} Y_i^2$$

( $Y_i \sim N(0, 1)$  且独立) , 即  $(n-1)s^2 \sim \sigma^2 \chi^2(n-1)$ 。

构造正交矩阵

$$A = \begin{bmatrix} \frac{1}{\sqrt{n}} & \frac{1}{\sqrt{2}} & \cdots & \frac{-(n-1)}{\sqrt{n(n-1)}} \\ \vdots & \vdots & & \vdots \\ \frac{1}{\sqrt{n}} & -\frac{1}{\sqrt{2}} & \cdots & \frac{1}{\sqrt{n(n-1)}} \end{bmatrix},$$

令  $Y = AX$ , 则  $Y \sim N(0, \sigma^2 I_n)$ 。

其中  $Y_1 = \sqrt{n}\bar{X}$ , 且

$$s^2 = \frac{1}{n-1} \sum_{i=2}^n Y_i^2$$

由于  $Y_1, Y_2, \dots, Y_n$  相互独立, 故

$$s^2 \perp\!\!\!\perp Y_1 \implies s^2 \perp\!\!\!\perp \bar{X}.$$

-----

下面类似的我们给出  $(n-2)s^2 \sim \sigma^2 \chi^2(n-2)$  的证明

**proof**

令残差  $e_j = y_j - \hat{y}_j$ , 则有:

$$\begin{aligned} e_j &= y_j - (\hat{\alpha} + \hat{\beta}x_j) \\ &= \sum_{i=1}^n y_i \delta_{ij} - \left( \frac{1}{n} \sum_{i=1}^n y_i + \frac{(x_i - \bar{x})(x_j - \bar{x})}{s_{xx}} \sum_{i=1}^n y_i \right) \\ &= \sum_{i=1}^n \left[ \delta_{ij} - \frac{1}{n} - \frac{(x_i - \bar{x})(x_j - \bar{x})}{s_{xx}} \right] y_i = A_j^T y \end{aligned}$$

其中

$$A = \begin{bmatrix} A_1^T \\ A_2^T \\ \vdots \\ A_n^T \end{bmatrix} = I_n - B, \quad B_{ij} = \frac{1}{n} + \frac{(x_i - \bar{x})(x_j - \bar{x})}{s_{xx}}.$$

remark 矩阵  $B$  与  $A$  的性质

- $B$  是**对称幂等矩阵**:  $B^T = B$ , 且  $B^2 = B$  (可通过展开验证:  $B_{ij}^2 = \sum_{k=1}^n B_{ik} B_{kj} = \frac{1}{n} + \frac{(x_i - \bar{x})(x_j - \bar{x})}{s_{xx}} = B_{ij}$ ).
- $A$  是**对称幂等矩阵**: 因为  $A = I_n - B$ , 故  $A^T = A$  且  $A^2 = A$ .

$$\text{tr}(A) = \text{tr}(I_n) - \text{tr}(B) = n - \left( 1 + \frac{s_{xx}}{s_{xx}} \right) = n - 2$$

残差平方和:

$$(n-2)s^2 = \sum_{i=1}^n e_i^2 = e^T e = y^T A^T A y = \varepsilon^T A^T A \varepsilon = \varepsilon^T A \varepsilon$$

(因  $A$  幂等)。

对  $A$  进行正交特征分解  $A = Q^T \Lambda Q$ , 则:

$$(n-2)s^2 = \sigma^2 \sum_{i=1}^{n-2} Z_i^2, \quad Z_i \sim N(0, 1) \text{ 且独立}$$

故  $(n-2)s^2 \sim \sigma^2 \chi^2(n-2)$ 。

## sum of squares

---

### Total sum of squares (SST)

---

$$\text{SST} = \sum_{i=1}^n (y_i - \bar{y})^2$$

- $\frac{\text{SST}}{n-1}$ : Sample variance of  $y_i$
  - $df_{\text{SST}} = n - 1$
- 

### Regression sum of squares (SSR)

---

$$\text{SSR} = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

- 由  $\sum_{i=1}^n (y_i - \hat{y}_i) = \sum_{i=1}^n (y_i - \hat{\alpha} - \hat{\beta}x_i) = 0$ , 可得  $\text{SSR} = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$ 。
- $\frac{\text{SSR}}{1}$ : Mean square for regression (since  $df_{\text{SSR}} = 1$ )
- 进一步推导:

$$\text{SSR} = \sum_{i=1}^n (\hat{\alpha} + \hat{\beta}x_i - \bar{y})^2 = \sum_{i=1}^n (\hat{\beta}(x_i - \bar{x}))^2 = \hat{\beta}^2 \sum_{i=1}^n (x_i - \bar{x})^2 = \hat{\beta}^2 s_{xx},$$

其中  $s_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$  (固定值)。

- $df_{\text{SSR}} = 1$
- 

### Residual sum of squares (SSE)

---

$$\text{SSE} = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- 定义  $s^2 = \frac{\text{SSE}}{n-2}$ , 其中  $s^2$  为 Mean Square Error (MSE)
- 性质:  $E(s^2) = \sigma^2$  ( $s^2$  为  $\sigma^2$  的无偏估计)
- $df_{\text{SSE}} = n - 2$

## 均方 (Mean Square)

$$\text{Mean Square} = \frac{\text{Sum of Squares}}{df}$$

$$\text{SST} = \text{SSR} + \text{SSE}$$

展开总平方和:

$$\begin{aligned} \text{SST} &= \sum_{i=1}^n (y_i - \bar{y})^2 \\ &= \sum_{i=1}^n ((y_i - \hat{y}_i) + (\hat{y}_i - \bar{y}))^2 \\ &= \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + 2 \sum_{i=1}^n (y_i - \hat{y}_i)(\hat{y}_i - \bar{y}) \\ &= \text{SSE} + \text{SSR} + 2 \sum_{i=1}^n (y_i - \hat{y}_i)(\hat{y}_i - \bar{y}). \end{aligned}$$

### 交叉项为 0 的证明

需证

$$\sum_{i=1}^n (y_i - \hat{y}_i)(\hat{y}_i - \bar{y}) = 0.$$

从

$$\hat{y}_i = \hat{\alpha} + \hat{\beta}x_i, \quad \bar{y} = \hat{\bar{y}},$$

开始:

$$\begin{aligned} \sum_{i=1}^n (y_i - \hat{y}_i)(\hat{y}_i - \bar{y}) &= \sum_{i=1}^n (y_i - \hat{y}_i)\hat{y}_i \\ &= \sum_{i=1}^n (y_i - \hat{y}_i)(\hat{\alpha} + \hat{\beta}x_i) \\ &= \hat{\alpha} \sum_{i=1}^n (y_i - \hat{y}_i) + \hat{\beta} \sum_{i=1}^n (y_i - \hat{y}_i)x_i. \end{aligned}$$

- 第一项: 残差和为 0

$$\sum_{i=1}^n (y_i - \hat{y}_i) = 0.$$

- 第二项: 展开并化简

$$\begin{aligned} \sum_{i=1}^n (y_i - \hat{y}_i)x_i &= \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i (\hat{\alpha} + \hat{\beta}x_i) \\ &= \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i (\bar{y} - \hat{\beta}\bar{x} + \hat{\beta}x_i) \\ &= \sum_{i=1}^n x_i y_i - n\bar{x}\bar{y} + n\hat{\beta}\bar{x}^2 - \hat{\beta} \sum_{i=1}^n x_i^2 \\ &= x^T y - n\bar{x}\bar{y} - \hat{\beta}s_{xx} \\ &= s_{xy} - \frac{s_{xy}}{s_{xx}} \cdot s_{xx} = 0. \end{aligned}$$

因此交叉项为 0, 平方和分解成立:

$$\text{SST} = \text{SSR} + \text{SSE}.$$

---

判定系数  $r^2$

---

$$r^2 = \frac{\text{SSR}}{\text{SST}} = \frac{\text{SSR}}{\text{SSR} + \text{SSE}} \in [0, 1].$$

## 意义分析

- 若  $r^2 = 0$ :
  - $\text{SSR} = 0, \text{SST} = \text{SSE}$
  - 回归模型未能解释  $y$  的任何波动，拟合完全失败。
- 若  $r^2 = 1$ :
  - $\text{SSE} = 0$
  - 对所有  $i$ ,  $\hat{y}_i = y_i$ , 模型完美拟合数据，拟合效果极佳。

## Hypothesis Testing

### 检验假设

$$H_0 : \beta = 0 \quad \text{vs} \quad H_1 : \beta \neq 0$$

### 假设 $H_0$ 下的平方和分布

**总平方和 (SST)**  $\text{SST} \sim \sigma^2 \chi^2(n-1)$ .

$$\text{SST} = \|y - \bar{y}\mathbf{1}_n\|_2^2 = s_{yy}$$

其中

$$s_{yy} = y^T y - n\bar{y}^2 = y^T \left( I_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^T \right) y.$$

在  $H_0$  下,  $y = \alpha \mathbf{1}_n + \varepsilon$ , 令

$$H = I_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^T$$

(对称幂等矩阵), 则

$$s_{yy} = \varepsilon^T H \varepsilon.$$

对  $H$  进行谱分解  $H = U^T \Lambda U$ 。因为  $\text{tr}(H) = n - 1$ , 所以  $\Lambda$  有  $n - 1$  个特征值 1 和 1 个特征值 0。又  $\varepsilon \sim N(0, \sigma^2 I_n)$ , 因此  $U\varepsilon \sim N(0, \sigma^2 I_n)$ , 从而

$$\text{SST} \sim \sigma^2 \chi^2(n - 1).$$

## 回归平方和 (SSR) $\text{SSR} \sim \sigma^2 \chi^2(1)$

$$\text{SSR} = \|\hat{y} - \bar{y} \mathbf{1}_n\|_2^2 = \hat{\beta}^2 s_{xx} = \frac{s_{xy}^2}{s_{xx}}.$$

在  $H_0$  下,  $\hat{\beta} \sim N\left(0, \frac{\sigma^2}{s_{xx}}\right)$ , 因此

$$\frac{\text{SSR}}{\sigma^2} = \left( \frac{\hat{\beta}}{\sigma / \sqrt{s_{xx}}} \right)^2 \sim \chi^2(1),$$

即  $\text{SSR} \sim \sigma^2 \chi^2(1)$ 。

## 残差平方和 (SSE)

$$\text{SSE} = \|y - \hat{y}\|_2^2 = (n - 2)s^2,$$

其中  $s^2 = \frac{1}{n - 2} \sum_{i=1}^n (y_i - \hat{y}_i)^2$ 。此前已证在线性模型假设下

$$\text{SSE} \sim \sigma^2 \chi^2(n - 2)$$

且 SSE 与  $\begin{bmatrix} \hat{\alpha} \\ \hat{\beta} \end{bmatrix}$  独立。

---

## 基于 $F$ 统计量的检验

当  $H_0: \beta = 0$  成立时，回归平方和 SSR 倾向于较小值（模型无解释力），而残差方差  $s^2$  反映误差变异。

已知：

- $\text{SSR} \sim \sigma^2 \chi^2(1)$ ;
- $(n-2)s^2 \sim \sigma^2 \chi^2(n-2)$ , 即  $s^2 \sim \sigma^2 \frac{\chi^2(n-2)}{n-2}$ 。

构造  $F$  统计量：

$$F = \frac{\text{SSR}/1}{s^2} \sim F(1, n-2).$$

若  $F > F_\alpha(1, n-2)$  ( $F_\alpha(1, n-2)$  为  $F(1, n-2)$  的上  $\alpha$  分位数)，则 **拒绝**  $H_0$  (认为  $\beta \neq 0$ )；否则不拒绝  $H_0$ 。

---

## 基于 $t$ 统计量的检验

### $H_0$ 成立时 $\hat{\beta}$ 的分布

在  $H_0: \beta = 0$  下，

$$\hat{\beta} \sim N\left(0, \frac{\sigma^2}{s_{xx}}\right), \quad s_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2.$$

### 统计量推导

标准化：

$$\frac{\hat{\beta}}{\sqrt{\sigma^2/s_{xx}}} \sim N(0, 1).$$



用  $s^2$  替代  $\sigma^2$  ( $s^2$  为  $\sigma^2$  的无偏估计), 并结合  $(n-2)s^2/\sigma^2 \sim \chi^2(n-2)$ , 得到 Student  $t$  统计量:

$$t = \frac{\hat{\beta}}{\sqrt{s^2/s_{xx}}} = \frac{\hat{\beta}}{\sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{(n-2)s_{xx}}}} \sim t(n-2).$$

## 决策规则

若  $|t| > t_{\alpha/2}(n-2)$  ( $t_{\alpha/2}(n-2)$  为  $t_{n-2}$  的上  $\alpha/2$  分位数), 则 **拒绝**  $H_0$ ; 否则不拒绝。

## remark ( $F$ 与 $t$ 的等价性):

在单个回归系数的检验中有如下关系 (分布级别):

$$t^2 \sim F(1, n-2),$$

因此  $|t| > t_{\alpha/2}(n-2)$  等价于  $F > F_{\alpha}(1, n-2)$ , 两检验等价。

## 置信区间 (CI: Confidence Interval)

统计学习里我们很关注我们对于估计量的真实值的范围, 即我们很关注在得出估计量以后实际值的范围。

## 回归系数 $\beta$ 的置信区间

## 统计量分布

已知  $\hat{\beta} \sim N\left(\beta, \frac{\sigma^2}{s_{xx}}\right)$ , 且  $\frac{(n-2)s^2}{\sigma^2} \sim \chi^2(n-2)$ , 构造  $t$  统计量:

$$\frac{(\hat{\beta} - \beta)\sqrt{s_{xx}}}{s} \sim t(n-2)$$

## 置信区间推导

由置信水平  $1 - \alpha$ , 有:

$$P\left(\left|\frac{(\hat{\beta} - \beta)\sqrt{s_{xx}}}{s}\right| < t_{\alpha/2}(n-2)\right) = 1 - \alpha$$

整理得  $\beta$  的置信区间:

$$\hat{\beta} \pm t_{\alpha/2}(n-2) \cdot \frac{s}{\sqrt{s_{xx}}}$$

其中  $s^2 = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{y}_i)^2$ ,  $s_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$ .

---

## 均值 $\mu_0 = \alpha + \beta x_0$ 的置信区间 (mean response)

---

## 统计量分布

令  $\hat{\mu}_0 = \hat{\alpha} + \hat{\beta}x_0$ , 则:

$$\hat{\mu}_0 \sim N\left(\alpha + \beta x_0, \frac{\sigma^2}{n} + \frac{(x_0 - \bar{x})^2}{s_{xx}}\sigma^2\right)$$

构造  $t$  统计量 (用  $s$  替代  $\sigma$ ):

$$\frac{\hat{\mu}_0 - \mu_0}{\sqrt{\frac{s^2}{n} + \frac{(x_0 - \bar{x})^2}{s_{xx}}s^2}} \sim t(n-2)$$

## 置信区间推导

由置信水平  $1 - \alpha$ , 有:

$$P\left(\left|\frac{\hat{\mu}_0 - \mu_0}{s\sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{s_{xx}}}}\right| < t_{\alpha/2}(n-2)\right) = 1 - \alpha$$

整理得  $\mu_0$  的置信区间:

$$\hat{\mu}_0 \pm t_{\alpha/2}(n-2) \cdot s \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{s_{xx}}}$$

## 个体预测值 $y_{n+1} = \alpha + \beta x_{n+1} + \varepsilon_{n+1}$ 的置信区间 (预测区间)

### 统计量分布

令  $\hat{y}_{n+1} = \hat{\alpha} + \hat{\beta}x_{n+1}$ , 则预测误差为:

$$y_{n+1} - \hat{y}_{n+1} = (\alpha + \beta x_{n+1} + \varepsilon_{n+1}) - (\hat{\alpha} + \hat{\beta}x_{n+1})$$

因  $\varepsilon_{n+1}$  与  $\hat{\alpha}, \hat{\beta}$  独立, 且

$$\hat{\alpha} + \hat{\beta}x_{n+1} \sim N\left(\alpha + \beta x_{n+1}, \frac{\sigma^2}{n} + \frac{(x_{n+1} - \bar{x})^2}{s_{xx}}\sigma^2\right)$$

且  $\varepsilon_{n+1} \sim N(0, \sigma^2)$ , 故:

$$y_{n+1} - \hat{y}_{n+1} \sim N\left(0, \sigma^2 \left(1 + \frac{1}{n} + \frac{(x_{n+1} - \bar{x})^2}{s_{xx}}\right)\right)$$

构造  $t$  统计量 (用  $s$  替代  $\sigma$ ):

$$\frac{y_{n+1} - \hat{y}_{n+1}}{s \sqrt{1 + \frac{1}{n} + \frac{(x_{n+1} - \bar{x})^2}{s_{xx}}}} \sim t(n-2)$$

### 置信区间 (预测区间) 推导

由置信水平  $1 - \alpha$ , 有:

$$P\left(\left|\frac{y_{n+1} - \hat{y}_{n+1}}{s \sqrt{1 + \frac{1}{n} + \frac{(x_{n+1} - \bar{x})^2}{s_{xx}}}}\right| < t_{\alpha/2}(n-2)\right) = 1 - \alpha$$

整理得  $y_{n+1}$  的预测区间：

$$\hat{y}_{n+1} \pm t_{\alpha/2}(n-2) \cdot s \sqrt{1 + \frac{1}{n} + \frac{(x_{n+1} - \bar{x})^2}{s_{xx}}}$$

**说明：**预测区间比均值的置信区间更宽，因为它不仅包含了估计  $\mu_0$  的误差，还包含了个体误差  $\varepsilon_{n+1}$  的波动。