

Multiple Linear Regression

TOC

- [TOC](#)
- [模型基础](#)
- [Estimator of Parameters](#)
 - [LSE \(最小二乘估计\)](#)
 - [投影矩阵 \$H\$ 的性质](#)
 - [BLUE \(最佳线性无偏估计\)](#)
 - [MLE \(极大似然估计\)](#)
 - [对 \$\sigma^2\$ 的极大似然估计](#)
- [Qualities](#)
 - [\$\beta\$ 参数估计](#)
 - [\$\sigma^2\$ 的无偏估计](#)
 - [\$s^2 \perp\!\!\!\perp b\$](#)
- [CI: Confidence Interval \(置信区间\)](#)
 - [① 对 \$\beta_i\$ 的置信区间推导](#)
 - [② Mean Response \(均值响应的置信区间\)](#)
 - [矩阵与模型设定](#)
 - [③ \$Y_{n+1}\$: Actual Response \(实际响应的置信区间\)](#)
- [Sum of squares](#)
 - [总平方和 \(SST\)](#)
 - [回归平方和 \(SSR\)](#)
 - [残差平方和 \(SSE\)](#)
- [Model fitness \(模型拟合优度\)](#)
 - [\$R^2\$](#)

- R_a^2 (Adjusted R^2 , 调整后判定系数)
- Hypothesis Testing (假设检验)
 - $H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0$
 - $H_0^* : \beta_i = 0$
- 多因素回归的系数约束检验
 - 交互效应模型转换
 - 一般约束形式 $C\beta = 0_m$
 - Extra Sum of Square(for reduced model)
 - 全模型设定
 - 模型拆分与约简模型
 - 约简模型的平方和与额外平方和推导
 - 回至主线：带约束的模型检验
 - 约束假设与参数拆分
 - 为什么可以这么拆分
 - 约简模型
 - 平方和定义 (约简模型与全模型对比)
 - 约束假设下的平方和差异检验
 - 检验逻辑
 - 平方和差异的定义与模型设定
 - 带约束的最小二乘估计推导 (拉格朗日乘数法)
 - 约束假设下的 F 检验推导
 - 检验逻辑与前提
 - 平方和差异的分布分析
 - 均方误差与 F 统计量构造
 - 决策规则
 - remark
 - 约束假设检验的实例推导
 - 例 1：单个回归系数的显著性检验
 - 例 2：多个回归系数的联合显著性检验

前面介绍了一元的线性回归模型，现介绍多元模型

模型基础

observations $(y_i, x_{i1}, x_{i2}, \dots, x_{ik}), i = 1, 2, \dots, n$

x_{ij} 表示第 i 次观测到的第 j 个解释变量

Model: $y_i = \beta_0 + x_{i1}\beta_1 + x_{i2}\beta_2 + \dots + x_{ik}\beta_k + \varepsilon_i$

其中, $E(\varepsilon_i) = 0$, $\text{Var}(\varepsilon_i) = \sigma^2$, $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0$

用矩阵形式表现则为：

$$Y = \beta_0 \mathbf{1}_n + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k + \varepsilon$$

$$= [\mathbf{1}_n, X_1, X_2, \dots, X_k] \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{bmatrix} + \varepsilon$$

$$= X\beta + \varepsilon$$

其中, $X = [\mathbf{1}_n, X_1, X_2, \dots, X_k]$

且有 $E(Y) = X\beta$, $\text{Cov}(Y) = \sigma^2 I_n$

可以知道 X 的每一行是一个观测数据, 每一列是一个解释变量的取值

Estimator of Parameters

LSE (最小二乘估计)

根据向量的一些基本定理我们可以得到

$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2} + \dots + \hat{\beta}_k x_{ik} = [1, x_{i1}, x_{i2}, \dots, x_{ik}] \hat{\beta} = x_i^T \hat{\beta}$ (其中 x_i^T 指 X 中第 i 行)

所以我们有 $\hat{Y} = X\hat{\beta}$

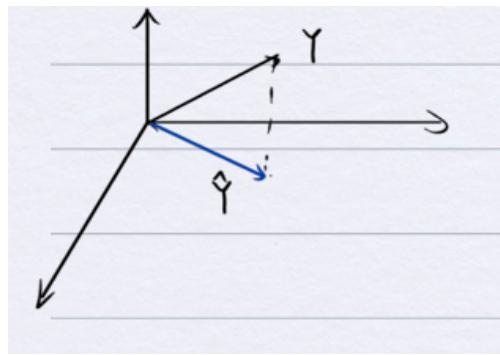
$$\hat{\beta} = \arg \min e_i^2 = \arg \min \|Y - \hat{Y}\|^2 = \arg \min \|Y - X\beta\|^2$$

对 β 求导并令其为 0, 有 $-X^T(Y - X\beta) = 0$, 则 $\hat{\beta}_{\text{LSE}} = (X^T X)^{-1} X^T Y$

$$\hat{Y} = (\mathbf{1}_n, X_1, X_2, \dots, X_k) \hat{\beta} \in \text{span}\{\mathbf{1}_n, X_1, \dots, X_k\}$$

从几何投影角度, $\hat{Y} = HY = X(X^T X)^{-1} X^T Y = X\hat{\beta}_{\text{LSE}}$ (其中 H 为投影矩阵)

投影矩阵 H 的性质



H 称为投影矩阵, 性质良好, 现说明如下:

① Symmetric (对称)

$$H^T = H$$

验证:

$$(X(X^T X)^{-1} X^T)^T = X((X^T X)^{-1})^T X^T = X((X^T X)^T)^{-1} X^T = X(X^T X)^{-1} X^T$$

② Idempotent (幂等)

$$H^2 = H$$

验证:

$$(X(X^T X)^{-1} X^T)^2 = X(X^T X)^{-1} X^T X(X^T X)^{-1} X^T = X(X^T X)^{-1} X^T$$

③ 由对称和幂等性质可得

H 的特征值只有 0 和 1。

因此, 迹 $\text{tr}(H) = \text{tr}(X(X^T X)^{-1} X^T) = \text{tr}((X^T X)^{-1} X^T X) = \text{tr}(I_{k+1}) = k + 1$ 。

故 H 的特征值 1 的几何重数为 $k + 1$, 特征值 0 的几何重数为 $n - k - 1$ 。

④ 投影 (后续可能用到)

$$HX = X, H\mathbf{1}_n = \mathbf{1}_n$$

BLUE (最佳线性无偏估计)

下证从 BLUE 角度出发，得到的 $\hat{\beta}_{\text{BLUE}}$ 与极大似然估计 $\hat{\beta}_{\text{MLE}}$ 一致。

设 $\tilde{\beta} = [(X^T X)^{-1} X^T + \Delta] Y$ ，其中 Δ 是待分析的矩阵。

要使 $\tilde{\beta}$ 是无偏估计，需满足 $E(\tilde{\beta}) = \beta$ 。

代入 $Y = X\beta + \varepsilon$ (其中 $E(\varepsilon) = 0$)，得：

$$\begin{aligned} E(\tilde{\beta}) &= [(X^T X)^{-1} X^T + \Delta] E(Y) \\ &= [(X^T X)^{-1} X^T + \Delta] (X\beta) \\ &= \beta + \Delta X\beta \end{aligned}$$

令 $E(\tilde{\beta}) = \beta$ ，需满足 $\Delta X = 0$ 。

已知 $\text{Cov}(Y) = \sigma^2 I_n$ ，则：

$$\begin{aligned} \text{Cov}(\tilde{\beta}) &= [(X^T X)^{-1} X^T + \Delta] \text{Cov}(Y) [(X^T X)^{-1} X^T + \Delta]^T \\ &= \sigma^2 [(X^T X)^{-1} X^T + \Delta] [X(X^T X)^{-1} + \Delta^T] \end{aligned}$$

结合 $\Delta X = 0$ 展开并化简：

$$\begin{aligned} \text{Cov}(\tilde{\beta}) &= \sigma^2 [(X^T X)^{-1} + \Delta \Delta^T + \Delta X (X^T X)^{-1} + (X^T X)^{-1} (\Delta X)^T] \\ &= \sigma^2 [(X^T X)^{-1} + \Delta \Delta^T] \end{aligned}$$

由于 $\Delta \Delta^T$ 是半正定矩阵，根据半正定矩阵的性质，有：

$$\text{Cov}(\tilde{\beta}) \succeq \sigma^2 (X^T X)^{-1}$$

且等号成立的充要条件是 $\Delta = 0$ (若 $\Delta \neq 0$ ，则存在 i, j 使得 $[\Delta \Delta^T]_{ij} > 0$)。

$\hat{\beta}_{\text{LSE}} = (X^T X)^{-1} X^T Y$ 是 β 的最佳线性无偏估计 (BLUE)；在正态分布假设下，它与极大似然估计 $\hat{\beta}_{\text{MLE}}$ 完全一致。

MLE (极大似然估计)

在多元线性回归模型的正态假设下，极大似然估计 (MLE) 的推导如下：

多元线性回归模型为 $Y = X\beta + \varepsilon$ ，其中随机误差 $\varepsilon \sim N(0, \sigma^2 I_n)$ ，因此条件分布 $Y|X \sim N(X\beta, \sigma^2 I_n)$ 。

- 概率密度函数 (pdf) :

$$f(Y) = \frac{1}{(2\pi)^{\frac{n}{2}}(\sigma^2)^{\frac{n}{2}}} \exp \left\{ -\frac{1}{2}(Y - X\beta)^T \frac{1}{\sigma^2} (Y - X\beta) \right\}$$

- 对数似然函数:

对 β 的对数似然 $\ell(\beta)$ 为:

$$\ell(\beta) = -\frac{n}{2} \ln 2\pi - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} (Y - X\beta)^T (Y - X\beta)$$

最大化 $\ell(\beta)$ 等价于最小化残差平方和 $(Y - X\beta)^T (Y - X\beta)$, 因此:

$$\hat{\beta}_{\text{MLE}} = \arg \min_{\beta} (Y - X\beta)^T (Y - X\beta) = \hat{\beta}_{\text{LSE}}$$

即 β 的极大似然估计与最小二乘估计 (LSE) 完全一致。

对 σ^2 的极大似然估计

将对数似然函数关于 σ^2 展开:

$$\ell(\sigma^2) = -\frac{n}{2} \ln 2\pi - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} (Y - X\beta)^T (Y - X\beta)$$

最大化 $\ell(\sigma^2)$ 等价于最小化 $\frac{n}{2} \ln \sigma^2 + \frac{1}{2\sigma^2} (Y - X\beta)^T (Y - X\beta)$ 。对 σ^2 求导并令导数为 0:

$$\frac{n}{2} \cdot \frac{1}{\sigma^2} - \frac{1}{2(\sigma^2)^2} (Y - X\hat{\beta})^T (Y - X\hat{\beta}) = 0$$

解得 σ^2 的极大似然估计:

$$\hat{\sigma}^2 = \frac{1}{n} \|Y - X\hat{\beta}\|_2^2 = \frac{1}{n} \|Y - \hat{Y}\|_2^2$$

Qualities

β 参数估计

回归系数的估计: $b = (X^T X)^{-1} X^T Y = \hat{\beta}$

在正态假设下, $b \sim N(\beta, \sigma^2(X^T X)^{-1})$

σ^2 的无偏估计

σ^2 的极大似然估计 (MLE)

$$\hat{\sigma}_{\text{MLE}}^2 = \frac{1}{n} \|Y - \hat{Y}\|_2^2 = \frac{1}{n} \|Y - Xb\|_2^2$$

$\hat{\sigma}_{\text{MLE}}^2$ 的期望

推导过程:

$$\begin{aligned} E(\hat{\sigma}_{\text{MLE}}^2) &= \frac{1}{n} E\|Y - Xb\|_2^2 = \frac{1}{n} E\|Y - HY\|_2^2 \quad (\text{因 } \hat{Y} = HY) \\ &= \frac{1}{n} E[Y^T(I - H)^T(I - H)Y] \quad (\text{因 } I - H \text{ 幂等}) \\ &= \frac{1}{n} E[Y^T(I - H)Y] \\ &= \frac{1}{n} E[(X\beta + \varepsilon)^T(I - H)(X\beta + \varepsilon)] \\ &= \frac{1}{n} E[\varepsilon^T(I - H)\varepsilon] \quad (\text{因 } (I - H)X = 0) \\ &= \frac{1}{n} E[\text{tr}(\varepsilon^T(I - H)\varepsilon)] \\ &= \frac{1}{n} \text{tr}[(I - H)\text{Cov}(\varepsilon)] \\ &= \frac{1}{n} \text{tr}[(I - H)\sigma^2 I_n] \\ &= \frac{\sigma^2}{n} \text{tr}(I - H) \\ &= \frac{\sigma^2}{n}(n - k - 1) \end{aligned}$$

可见 $E(\hat{\sigma}_{\text{MLE}}^2) \neq \sigma^2$, 即 $\hat{\sigma}_{\text{MLE}}^2$ 有偏。

修正后得到无偏估计:

$$s^2 = \frac{\hat{\sigma}_{\text{MLE}}^2}{\frac{n-k-1}{n}} = \frac{1}{n-k-1} \|Y - Xb\|_2^2$$

且 $E(s^2) = \sigma^2$

$$s^2 \perp\!\!\!\perp b$$

$s^2 = \frac{1}{n-k-1} \|Y - Xb\|_2^2$, 证明 $Y - Xb \perp\!\!\!\perp b$ 即可。

其中, $Y - Xb = Y - HY = (I - H)Y$, $b = (X^T X)^{-1} X^T Y$ 。

向量组 $\begin{pmatrix} Y - Xb \\ b \end{pmatrix} = \begin{pmatrix} I - H \\ (X^T X)^{-1} X^T \end{pmatrix} Y$ 满足联合正态。

协方差推导:

$$\begin{aligned} \text{Cov}(Y - Xb, b) &= \text{Cov}((I - H)Y, (X^T X)^{-1} X^T Y) \\ &= (I - H)\text{Cov}(Y)X(X^T X)^{-1} \\ &= 0 \end{aligned}$$

CI: Confidence Interval (置信区间)

(模型: $Y = X\beta + \varepsilon$)

① 对 β_i 的置信区间推导

- 由 $b \sim N(\beta, \sigma^2(X^T X)^{-1})$, 可得第 i 个回归系数的分布:

$$b_i \sim N\left(\beta_i, \sigma^2(X^T X)_{[i+1, i+1]}^{-1}\right)$$

其中 $(X^T X)_{[i+1, i+1]}^{-1}$ 表示矩阵 $(X^T X)^{-1}$ 的第 $i+1$ 行第 $i+1$ 列元素。

- 构造标准正态变量:

$$\frac{b_i - \beta_i}{\sigma \sqrt{(X^T X)_{[i+1, i+1]}^{-1}}} \sim N(0, 1)$$

- 代入 σ^2 的无偏估计 s^2 ($s^2 = \frac{1}{n-k-1} \|Y - Xb\|_2^2$), 且 $\frac{(n-k-1)s^2}{\sigma^2} \sim \chi^2(n-k-1)$, 根据 t 分布定义:

$$\frac{b_i - \beta_i}{\sigma \sqrt{(X^T X)_{[i+1, i+1]}^{-1}}} \sqrt{\frac{\sigma^2}{s^2}} = \frac{b_i - \beta_i}{s \sqrt{(X^T X)_{[i+1, i+1]}^{-1}}} \sim t(n-k-1)$$

- 因此, β_i 的置信区间为:

$$|b_i - \beta_i| \leq t_{\frac{\alpha}{2}}(n - k - 1) \cdot s \sqrt{(X^T X)^{-1}_{[i+1, i+1]}}$$

其中 $t_{\frac{\alpha}{2}}(n - k - 1)$ 是自由度为 $n - k - 1$ 的 t 分布上 $\frac{\alpha}{2}$ 分位数。

② Mean Response (均值响应的置信区间)

目标: 构建 $E(Y_{n+1} | x_{n+1}^T) = \mu_{n+1}$ 的置信区间

矩阵与模型设定

设计矩阵 $X \triangleq \begin{bmatrix} x_1^T \\ x_2^T \\ \vdots \\ x_n^T \end{bmatrix}$, 其中每行是一个观测, 每列是一个特征。

多元线性回归模型的条件期望:

- 整体条件期望: $E(Y | X) = X\beta$
- 单个观测的条件期望: $E(Y_i | x_i^T) = x_i^T \beta$

回归系数的最小二乘估计: $b = (X^T X)^{-1} X^T Y$

- 均值响应的真实值: $\mu_{n+1} = x_{n+1}^T \beta$
- 均值响应的估计值: $\hat{\mu}_{n+1} = x_{n+1}^T b$

估计误差的分布:

$$\hat{\mu}_{n+1} - \mu_{n+1} = x_{n+1}^T (b - \beta) \sim N(0, \sigma^2 x_{n+1}^T (X^T X)^{-1} x_{n+1})$$

代入 σ^2 的无偏估计 s^2 ($s^2 = \frac{1}{n-k-1} \|Y - Xb\|_2^2$), 构造 t 统计量:

$$\frac{\hat{\mu}_{n+1} - \mu_{n+1}}{\sigma \sqrt{x_{n+1}^T (X^T X)^{-1} x_{n+1}}} \sqrt{\frac{\sigma^2}{s^2}} = \frac{\hat{\mu}_{n+1} - \mu_{n+1}}{s \sqrt{x_{n+1}^T (X^T X)^{-1} x_{n+1}}} \sim t(n - k - 1)$$

因此, μ_{n+1} 的置信区间为:

$$|\mu_{n+1} - \hat{\mu}_{n+1}| < t_{n-k-1} \left(\frac{\alpha}{2} \right) \cdot s \sqrt{x_{n+1}^T (X^T X)^{-1} x_{n+1}}$$

其中 $t_{n-k-1} \left(\frac{\alpha}{2} \right)$ 是自由度为 $n - k - 1$ 的 t 分布上 $\frac{\alpha}{2}$ 分位数。

③ Y_{n+1} : Actual Response (实际响应的置信区间)

目标: 已知 x_{n+1} , 构建 Y_{n+1} 的置信区间

实际响应的模型: $Y_{n+1} = x_{n+1}^T \beta + \varepsilon_{n+1}$

估计响应与实际响应的误差:

$$\begin{aligned}\hat{Y}_{n+1} - Y_{n+1} &= x_{n+1}^T (b - \beta) - \varepsilon_{n+1} \\ &= x_{n+1}^T (X^T X)^{-1} X^T (X\beta + \varepsilon) - \beta - \varepsilon_{n+1} \\ &= x_{n+1}^T (X^T X)^{-1} X^T \varepsilon - \varepsilon_{n+1} \\ &= [x_{n+1}^T (X^T X)^{-1} X^T, -1] \begin{bmatrix} \varepsilon \\ \varepsilon_{n+1} \end{bmatrix}\end{aligned}$$

由 $\varepsilon \sim N(0, \sigma^2 I_n)$, $\varepsilon_{n+1} \sim N(0, \sigma^2)$ 且与 ε 独立, 可知 $\hat{Y}_{n+1} - Y_{n+1} \sim N(0, \text{Var})$, 其中方差:

$$\begin{aligned}\text{Var} &= \sigma^2 [x_{n+1}^T (X^T X)^{-1} X^T, -1] \begin{bmatrix} X(X^T X)^{-1} x_{n+1} \\ -1 \end{bmatrix} \\ &= \sigma^2 (x_{n+1}^T (X^T X)^{-1} x_{n+1} + 1)\end{aligned}$$

代入 σ^2 的无偏估计 s^2 ($s^2 = \frac{1}{n-k-1} \|Y - Xb\|_2^2$), 构造 t 统计量:

$$\frac{|\hat{Y}_{n+1} - Y_{n+1}|}{s \sqrt{x_{n+1}^T (X^T X)^{-1} x_{n+1} + 1}} \sim t(n - k - 1)$$

因此, Y_{n+1} 的置信区间为:

$$|\hat{Y}_{n+1} - Y_{n+1}| \leq t_{n-k-1} \left(\frac{\alpha}{2} \right) \cdot s \sqrt{x_{n+1}^T (X^T X)^{-1} x_{n+1} + 1}$$

其中 $t_{n-k-1} \left(\frac{\alpha}{2} \right)$ 是自由度为 $n - k - 1$ 的 t 分布上 $\frac{\alpha}{2}$ 分位数。

Sum of squares

总平方和 (SST)

$$\begin{aligned}\text{SST} &= \|Y - \bar{Y}\mathbf{1}_n\|_2^2 \\ &= Y^T Y + n\bar{Y}^2 - 2\bar{Y}\mathbf{1}_n^T Y \\ &= Y^T Y - n\bar{Y}^2 \\ &= Y^T \left(I - \frac{\mathbf{1}_n \mathbf{1}_n^T}{n} \right) Y\end{aligned}$$

其自由度: $\text{tr} \left(I - \frac{\mathbf{1}_n \mathbf{1}_n^T}{n} \right) = n - 1$

回归平方和 (SSR)

$$\begin{aligned}\text{SSR} &= \|\hat{Y} - \bar{Y}\mathbf{1}_n\|_2^2 \\ &= \|HY - \bar{Y}\mathbf{1}_n\|_2^2 \quad (\text{因 } \hat{Y} = HY) \\ &= Y^T HY + \bar{Y}^2 n - 2\bar{Y}\mathbf{1}_n^T HY \quad (\text{因 } \mathbf{1}_n \text{ 经 } H \text{ 变换后仍为 } \mathbf{1}_n) \\ &= Y^T HY - n\bar{Y}^2 \\ &= Y^T \left(H - \frac{\mathbf{1}_n \mathbf{1}_n^T}{n} \right) Y\end{aligned}$$

其自由度: $\text{tr} \left(H - \frac{\mathbf{1}_n \mathbf{1}_n^T}{n} \right) = k + 1 - 1 = k$

残差平方和 (SSE)

$$\begin{aligned}\text{SSE} &= \|\hat{Y} - Y\|_2^2 \\ &= \|HY - Y\|_2^2 \\ &= \|(H - I)Y\|_2^2 \\ &= Y^T (I - H)Y\end{aligned}$$

其自由度: $\text{tr}(I - H) = n - k - 1$

平方和分解关系: $\text{SST} = \text{SSR} + \text{SSE}$

Model fitness (模型拟合优度)

R^2

判定系数公式：

$$R^2 = \frac{\text{SSR}}{\text{SST}} = 1 - \frac{\text{SSE}}{\text{SST}}$$

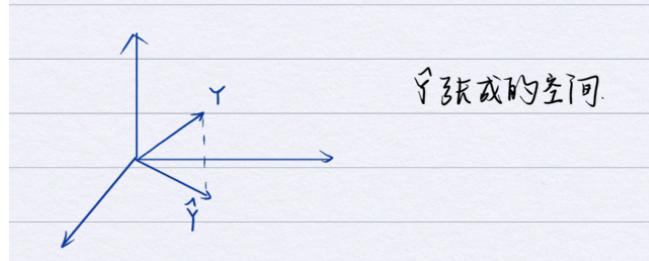
影响规律：解释变量个数 ($k \uparrow$) 时，($\text{SSE} \downarrow$)，($R^2 \uparrow$)

推导与本质：

$$\begin{aligned} R^2 &= \frac{\|\hat{Y} - \bar{Y}\|_2^2}{\|Y - \bar{Y}\|_2^2} = \frac{\|\hat{Y} - \bar{Y}\|_2^2}{\|\hat{Y} - \bar{Y}\|_2^2 + \|\hat{Y} - Y\|_2^2} \\ &= \frac{[Y^T (H - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^T) Y]^2}{\|Y - \bar{Y} \mathbf{1}_n\|_2^4} \\ &= \frac{[Y^T (H - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^T) (I_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^T) Y]^2}{\|Y - \bar{Y} \mathbf{1}_n\|_2^4} \\ &= \frac{[(\hat{Y} - \bar{Y})^T (Y - \bar{Y})]^2}{\|Y - \bar{Y}\|_2^2 \cdot \|\hat{Y} - \bar{Y}\|_2^2} \\ &= \text{Corr}^2(\hat{Y} - \bar{Y}, Y - \bar{Y}) \end{aligned}$$

- 几何意义 (右侧图形) :

图中展示了因变量 (Y)、拟合值 (\hat{Y}) 在空间中的投影关系，(\hat{Y}) 是 (Y) 向 (X) 张成的列空间的投影，(R^2) 量化了这种投影与 (Y) 本身的契合程度 (“(Y) 张成的空间”为辅助理解的几何背景)。



R_a^2 (Adjusted R^2 , 调整后判定系数)

- 形式一：

$$R_a^2 = 1 - \frac{\text{MSE}}{\text{MST}}$$

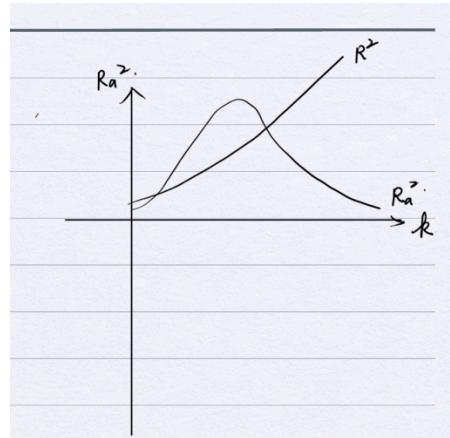
- 形式二 (展开推导) :

$$R_a^2 = 1 - \frac{\text{SSE}}{\text{SST}} \cdot \frac{n-1}{n-k-1}$$

变化规律 (基于解释变量个数 k 的影响)

- 当 k 较小时: $R_a^2 \approx 1 - \frac{\text{SSE}}{\text{SST}}$, 此时 $k \uparrow$ 会带动 $R_a^2 \uparrow$ 。
- 当 k 较大时: $R_a^2 \approx 1 - \frac{n-1}{n-k-1}$, 此时 $k \uparrow$ 会导致 $R_a^2 \downarrow$ 。

图中展示了 R^2 和 R_a^2 随解释变量个数 k 变化的趋势:



- R^2 随 k 增大单调递增;
- R_a^2 随 k 增大先上升后下降, 存在一个峰值点, 体现了其对解释变量个数的“惩罚性”调整。

Hypothesis Testing (假设检验)

$$H_0 : \beta_1 = \beta_2 = \cdots = \beta_k = 0$$

模型设定: $Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + \varepsilon$

原假设: $H_0 : \beta_1 = \beta_2 = \cdots = \beta_k = 0$

F 统计量定义: $F \triangleq \frac{\text{MSR}}{\text{MSE}} \sim F_{k, n-k-1}$

决策规则: 若 $F > F_{k, n-k-1}(\alpha)$, 则拒绝 H_0

$$H_0^* : \beta_i = 0$$

t 检验推导：

已知回归系数估计量的分布 $b \sim N(\beta, \sigma^2(X^T X)^{-1})$, 因此第 i 个回归系数的分布为:

$$b_i \sim N\left(\beta_i, \sigma^2(X^T X)_{[i+1, i+1]}^{-1}\right)$$

其中 $(X^T X)_{[i+1, i+1]}^{-1}$ 表示矩阵 $(X^T X)^{-1}$ 的第 $i+1$ 行第 $i+1$ 列元素。

构造 t 统计量:

$$\frac{\frac{b_i - \beta_i}{\sigma \sqrt{(X^T X)_{[i+1, i+1]}^{-1}}}}{\frac{s}{\sigma}} = \frac{b_i - \beta_i}{s \sqrt{(X^T X)_{[i+1, i+1]}^{-1}}} \sim t(n - k - 1)$$

当检验 $H_0^* : \beta_i = 0$ 时, 统计量简化为:

$$t \triangleq \frac{b_i}{s \sqrt{(X^T X)_{[i+1, i+1]}^{-1}}}$$

• 决策规则:

若 $|t| > t_{(n-k-1)}(\frac{\alpha}{2})$, 则拒绝 H_0^* 。

多因素回归的系数约束检验

交互效应模型转换

考虑含两个因素的回归模型:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon \quad (1)$$

若需解释 $x_1 - x_2$ 的交互效应, 可将模型转换为:

$$y = \beta_0 + \beta_1(x_1 - x_2) + \varepsilon = \beta_0 + \beta_1 x_1 - \beta_1 x_2 + \varepsilon \quad (2)$$

此时在模型 (1) 中, 需满足约束 $\beta_1 + \beta_2 = 0$, 即 (1) 可通过该约束转换为 (2)。

一般约束形式 $C\beta = 0_m$

- 回归系数向量:

$$\beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{bmatrix}_{(k+1) \times 1}$$

- 约束矩阵:

C 为 $m \times (k + 1)$ 矩阵, 用于表示对 β 的线性约束。

示例 1 ($\beta_1 + \beta_2 = 0$)

约束矩阵:

$$C = [0 \ 1 \ 1 \ 0 \ \dots \ 0]$$

则

$$C\beta = [0 \ 1 \ 1 \ 0 \ \dots \ 0] \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{bmatrix} = \beta_1 + \beta_2 = 0$$

示例 2 ($\beta_i = \beta_j = 0$)

约束矩阵:

$$C = \begin{bmatrix} 0 & \dots & 1 & \dots & 0 \\ 0 & \dots & 0 & \dots & 1 \end{bmatrix}_{(j+1) \times (k+1)}$$

则

$$C\beta = \begin{bmatrix} \beta_i \\ \beta_j \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

Extra Sum of Square(for reduced model)

全模型设定

模型形式：

$$Y = \tilde{X}\tilde{\beta} + \varepsilon = \beta_0 \mathbf{1}_n + (X_1 \dots X_k) \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{bmatrix} + \varepsilon$$

其中， $\tilde{X} = (\mathbf{1}_n \mid X)$ 是 $n \times (k+1)$ 矩阵， $\tilde{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{bmatrix}$ 是 $(k+1) \times 1$ 向量，解释变量个数

#变量 = k 。

- 全模型残差平方和 (SSE_F) :

$$\text{SSE}_F = Y^T(I - H_F)Y$$

其中投影矩阵 $H_F = \tilde{X}(\tilde{X}^T\tilde{X})^{-1}\tilde{X}^T$, $\tilde{X} = (\mathbf{1}_n \mid X)$.

- 全模型回归平方和 (SSR_F) :

$$\text{SSR}_F = Y^T \left(H_F - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^T \right) Y$$

模型拆分与约简模型

将设计矩阵拆分为 $X \triangleq (X_1 \mid X_2)$, 其中 X_1 是 $n \times k_1$ 矩阵, X_2 是 $n \times k_2$ 矩阵, 满足 $k_1 + k_2 = k$;

回归系数拆分为 $\beta = \begin{bmatrix} \beta_1 \\ \vdots \\ \beta_{k_1} \\ \beta_{k_1+1} \\ \vdots \\ \beta_k \end{bmatrix} \triangleq \begin{bmatrix} \beta_1 \\ \beta_2 \end{bmatrix}$, 其中 β_1 是 $k_1 \times 1$ 向量, β_2 是 $k_2 \times 1$ 向量 (将感兴趣的变量放在 X_1 里)。

约简模型 (Reduced Model) :

$$Y = \beta_0 \mathbf{1}_n + X_1 \beta_1 + \varepsilon$$

其中解释变量个数 #变量 = $k_1 < k$, 且此处的 β_0 、 β_1 可能与全模型中的系数不同。

约简模型的平方和与额外平方和推导

- 约简模型残差平方和 (SSE_R) :

$$SSE_R = Y^T (I - H_R) Y$$

其中投影矩阵 $H_R = \mathring{X} (\mathring{X}^T \mathring{X})^{-1} \mathring{X}^T$, $\mathring{X} = (\mathbf{1}_n \mid X_1)$ 是 $n \times (k_1 + 1)$ 矩阵 (表示向约简后的 \mathring{X} 张成的空间投影)。

- 约简模型回归平方和 (SSR_R) :

$$SSR_R = Y^T \left(H_R - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^T \right) Y$$

- 额外平方和定义:

全模型与约简模型的残差平方和之差, 即 $SSE_R - SSE_F = SSR(X_2 \mid X_1)$, 表示在 X_1 已入模的情况下, 加入 X_2 带来的**边缘回归平方和** (反映 X_2 对 Y 变异的额外解释能力)。

直观理解: SSE 可视为“距离”, 解释变量个数 $k \uparrow$ 时 $SSE \downarrow$; 由于全模型的 k 大于约简模型的 k_1 , 故 $SSE_R \geq SSE_F$ 。

- 特殊情况:

若 X_2 是 X_1 的线性组合, 则 X_2 无法带来额外解释能力, 此时 $SSE_R \approx SSE_F$ 。

回至主线: 带约束的模型检验

约束假设与参数拆分

原假设: $H_0: C\beta = 0$, 其中 C 是 $m \times (k + 1)$ 约束矩阵, β 是 $(k + 1) \times 1$ 回归系数向量。

- 约束性质: m 个方程, $k + 1$ 个参数, 且 $m < k + 1$ 。
- 参数拆分: 由于有 $k + 1 - m$ 个参数可变, 将 β 拆分为

$$\beta = \begin{bmatrix} \beta_0 \\ \vdots \\ \beta_{k-m} \\ * \end{bmatrix} \triangleq \begin{bmatrix} \eta \\ A\eta \end{bmatrix}$$

其中 η 是 $(k - m + 1) \times 1$ 向量, A 是 $m \times (k - m + 1)$ 矩阵。

为什么可以这么拆分

(1) 将回归系数按自由度分块

将系数向量 β 按“自由参数”和“约束参数”分成两部分：

- 前 $(k - m + 1)$ 个参数是**自由参数**, 记为

$$\eta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_{k-m} \end{bmatrix}$$

维度为 $(k - m + 1) \times 1$ 。

- 后 m 个参数是**约束参数**, 记为

$$\gamma = \begin{bmatrix} \beta_{k-m+1} \\ \vdots \\ \beta_k \end{bmatrix}$$

维度为 $m \times 1$ 。

于是整体向量可写成分块形式：

$$\beta = \begin{bmatrix} \eta \\ \gamma \end{bmatrix}$$

(2) 将约束 $C\beta = 0$ 分块

约束是线性方程：

$$C\beta = 0$$

将 C 的列按 η 和 γ 的分块对应拆分：

- C_1 : C 的前 $(k - m + 1)$ 列, 维度为 $m \times (k - m + 1)$
- C_2 : C 的后 m 列, 维度为 $m \times m$, 且 $\text{rank}(C_2) = m$ (因 C 列满秩)

于是:

$$C\beta = C_1\eta + C_2\gamma = 0$$

(3) 由自由参数解出约束参数

由线性方程:

$$C_1\eta + C_2\gamma = 0$$

可解得:

$$\gamma = -C_2^{-1}C_1\eta$$

定义矩阵:

$$A = -C_2^{-1}C_1$$

其维度为 $m \times (k - m + 1)$ 。

于是约束参数 γ 可写为:

$$\gamma = A\eta$$

(4) 最终参数表达式

将 γ 代回向量 β :

$$\beta = \begin{bmatrix} \eta \\ A\eta \end{bmatrix}$$

这表明:

在约束 $C\beta = 0$ 下, 原本的 $(k + 1)$ 个参数全部可由 $(k - m + 1)$ 维的自由向量 η 唯一表示。

约简模型

全模型: $Y = X\beta + \varepsilon$, 其中 $X = (X_1 \mid X_2)$ (X_1 为 $n \times (k - m + 1)$ 矩阵, X_2 为 $n \times m$ 矩阵)。

代入参数拆分式，约简模型为：

$$\begin{aligned} Y &= X_1\eta + X_2A\eta + \varepsilon \\ &= (X_1 + X_2A)\eta + \varepsilon \\ &\triangleq \tilde{X}\eta + \varepsilon \end{aligned}$$

其中 $\tilde{X} = X_1 + X_2A$ 是 $n \times (k - m + 1)$ 矩阵，约简模型的解释变量个数 #变量 = $k - m$ 。

平方和定义（约简模型与全模型对比）

- 约简模型残差平方和 (SSE_R) :

$$SSE_R = Y^T(I - H_R)Y$$

其中投影矩阵 $H_R = \tilde{X}(\tilde{X}^T\tilde{X})^{-1}\tilde{X}^T$, $\tilde{X} = X_1 + X_2A$ 。

- 约简模型回归平方和 (SSR_R) :

$$SSR_R = Y^T \left(H_R - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^T \right) Y$$

- 全模型（无约束）:

- 回归平方和 (SSR_F) : $SSR_F = Y^T(H_F - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^T)Y$
- 残差平方和 (SSE_F) : $SSE_F = Y^T(I - H_F)Y$
- 投影矩阵 (H_F) : $H_F = X(X^T X)^{-1} X^T$, X 为全模型设计矩阵。

约束假设下的平方和差异检验

检验逻辑

- 若 H_0 未被拒绝，可认为 $SSE_R - SSE_F \approx 0$;
- 若 $SSE_R - SSE_F > A$, 则拒绝 H_0 , 其中 $\alpha = P(\text{Reject} \mid H_0)$ 为检验的显著性水平。

平方和差异的定义与模型设定

需明确 $SSE_R - SSE_F$ 的推导，定义：

- 约简模型 (满足 $H_0 : C\beta = 0$) : $Y = X\beta + \varepsilon$ 且 $C\beta = 0$, 其残差平方和 $\text{SSE}_R = \|Y - \hat{Y}_R\|_2^2 = \|Y - X\hat{\beta}\|_2^2$, 其中 $\hat{\beta} = \arg \min_{\beta} \|Y - X\beta\|_2^2$ s.t. $C\beta = 0$ 。
- 全模型: $Y = X\beta + \varepsilon$, 其残差平方和 $\text{SSE}_F = \|Y - \hat{Y}_F\|_2^2 = \|Y - Xb\|_2^2$ ($b = (X^T X)^{-1} X^T Y$ 为无约束最小二乘估计)。

带约束的最小二乘估计推导 (拉格朗日乘数法)

构造拉格朗日函数 (用于最小化残差平方和 $\|Y - X\hat{\beta}\|_2^2$, 约束为 $C\hat{\beta} = 0$) :

$$\mathcal{L}(\hat{\beta}, \lambda) = Y^T Y - 2Y^T X\hat{\beta} + \hat{\beta}^T X^T X\hat{\beta} + \lambda^T C\hat{\beta}$$

对 $\hat{\beta}$ 和拉格朗日乘数 λ 求偏导并令其为 0:

- 对 $\hat{\beta}$ 求导:

$$\frac{\partial \mathcal{L}}{\partial \hat{\beta}} = -2X^T Y + 2X^T X\hat{\beta} + C^T \lambda^T = 0$$

- 对 λ 求导:

$$\frac{\partial \mathcal{L}}{\partial \lambda} = C\hat{\beta} = 0$$

记无约束最小二乘估计为 $b = (X^T X)^{-1} X^T Y$, 对 $\hat{\beta}$ 的导数方程左乘 $(X^T X)^{-1}$:

$$-2(X^T X)^{-1} X^T Y + 2\hat{\beta} + (X^T X)^{-1} C^T \lambda^T = 0 \quad (3)$$

对约束方程 $C\hat{\beta} = 0$ 左乘 $C(X^T X)^{-1}$ 并结合式 ③, 解出 λ^T :

$$\lambda^T = 2 [C(X^T X)^{-1} C^T]^{-1} C(X^T X)^{-1} X^T Y$$

将 λ^T 代入式 ③, 整理得:

$$\begin{aligned} \hat{\beta} &= b - (X^T X)^{-1} C^T [C(X^T X)^{-1} C^T]^{-1} C b \\ &\triangleq b - \Delta b \end{aligned}$$

其中 $\Delta = (X^T X)^{-1} C^T [C(X^T X)^{-1} C^T]^{-1} C$ 为约束影响矩阵。

约简模型残差平方和 $\text{SSE}_R = \|Y - X\hat{\beta}\|_2^2$, 全模型残差平方和 $\text{SSE}_F = \|Y - Xb\|_2^2$, 两者的差异

为：

$$\begin{aligned}\text{SSE}_R - \text{SSE}_F &= \|Y - X(b - \Delta b)\|_2^2 - \|Y - Xb\|_2^2 \\&= \|X\Delta b\|_2^2 + 2(Y - Xb)^T X\Delta b \\&= \|X\Delta b\|_2^2 \quad (\text{因}(Y - \hat{Y}_F)^T X = Y^T(I - H_F)X = 0) \\&= b^T \Delta^T X^T X \Delta b \\&= b^T C^T [C(X^T X)^{-1} C^T]^{-1} C b\end{aligned}$$

其中利用了残差性质： $Y - \hat{Y}_F = (I - H_F)Y$, 且 $(I - H_F)X = 0$ (投影矩阵的正交性), 故交叉项 $(Y - Xb)^T X\Delta b = 0$ 。

约束假设下的 F 检验推导

检验逻辑与前提

原假设： $H_0 : C\beta = 0$,

其中 C 是 $m \times (k+1)$ 的约束矩阵, β 是 $(k+1) \times 1$ 的回归系数向量。

若 $\text{SSE}_R - \text{SSE}_F > A$ 则拒绝 H_0 , 其中显著性水平定义为

$$\alpha = P(\text{SSE}_R - \text{SSE}_F > A \mid H_0).$$

平方和差异的分布分析

记无约束 (full) 估计为 $b = (X^T X)^{-1} X^T Y$, 则在高斯误差假设下

$$b \sim N(\beta, \sigma^2 (X^T X)^{-1}).$$

考虑线性变换 Cb , 由于 C 为常矩阵,

$$Cb \sim N(C\beta, \sigma^2 C(X^T X)^{-1} C^T).$$

在原假设 H_0 下, $C\beta = 0$, 因此

$$Cb \sim N(0, \sigma^2 \Sigma), \quad \Sigma \triangleq C(X^T X)^{-1} C^T,$$

且 Σ 为 $m \times m$ 的对称正定矩阵 (若 C 列满秩, 则 $\text{rank}(\Sigma) = m$)。

于是有标准化的二次型:

$$\frac{1}{\sigma^2} (Cb)^T \Sigma^{-1} (Cb) \sim \chi^2(m).$$

另对平方和差异的矩阵表达式可写成 (等价形式) :

$$\text{SSE}_R - \text{SSE}_F = (Cb)^T [C(X^T X)^{-1} C^T]^{-1} (Cb) = (Cb)^T \Sigma^{-1} (Cb).$$

因此在 H_0 下

$$\frac{1}{\sigma^2} (\text{SSE}_R - \text{SSE}_F) \sim \chi^2(m).$$

均方误差与 F 统计量构造

记全模型 (full model) 残差平方和为 SSE_F , 其自由度为 $n - (k + 1)$ (有时记为 $n - k - 1$)。定义全模型残差均方:

$$\text{MSE}_F = \frac{\text{SSE}_F}{n - k - 1}.$$

已知在模型假设下

$$\frac{1}{\sigma^2} \text{SSE}_F \sim \chi^2(n - k - 1).$$

并且由投影矩阵的正交分解性质, 可证明 $\text{SSE}_R - \text{SSE}_F$ 与 SSE_F 相互独立, 因此可以用独立的卡方量比构造 F 统计量:

$$F \triangleq \frac{(\text{SSE}_R - \text{SSE}_F)/m}{\text{MSE}_F} = \frac{[(\text{SSE}_R - \text{SSE}_F)/\sigma^2]/m}{[\text{SSE}_F/\sigma^2]/(n - k - 1)} \stackrel{H_0}{\sim} F_{m, n-k-1}.$$

决策规则

计算观测到的统计量

$$F_{\text{obs}} = \frac{(\text{SSE}_R - \text{SSE}_F)/m}{\text{SSE}_F/(n - k - 1)}.$$

给定显著性水平 α , 查表 (或用软件) 得临界值 $F_{m,n-k-1}(\alpha)$ 。若

$$F_{\text{obs}} > F_{m,n-k-1}(\alpha),$$

则拒绝 H_0 ; 否则不拒绝 H_0 。

remark

$\text{SSE}_R - \text{SSE}_F$ 与 SSE_F 独立性说明 (关键点) :

矩阵 $(I - H)$ 与 H 正交, 且 $(I - H)X = 0$ (因为 $HX = X$) , 因此残差向量 e 与列空间 $\mathcal{C}(X)$ 中的任意向量正交。这一正交性质推导出:

- 由 Cb 可表示为 $C(X^T X)^{-1} X^T Y$ (属于 X 的线性变换空间) , 而 $e = (I - H)Y$ 属于与 X 列空间正交的空间;
 - 因为 Y 在高斯假设下为多元正态, 线性变换的分量如果互相正交且协方差为 0, 则它们相互独立;
 - 于是 $(\text{SSE}_R - \text{SSE}_F)$ (对应于 Cb 的平方型) 与 SSE_F (对应于 e 的平方和) 独立, 从而 F 统计量的推导合法。
-

约束假设检验的实例推导

例 1: 单个回归系数的显著性检验

假设设定: $H_0 : \beta_i = 0$, 等价于约束矩阵 $C = [0, \dots, 0, \underset{(i+1)}{1}, 0, \dots, 0]$, 满足 $C\beta = \beta_i$ 。

平方和差异与统计量构造:

根据前文推导, 平方和差异为:

$$\text{SSE}_R - \text{SSE}_F = (Cb)^T [C(X^T X)^{-1} C^T]^{-1} Cb$$

其中 $Cb = b_i$ (第 i 个回归系数的估计值) , $C(X^T X)^{-1} C^T = (X^T X)_{[i+1,i+1]}^{-1}$ (矩阵 $(X^T X)^{-1}$ 的第 $i + 1$ 行第 $i + 1$ 列元素) 。

因此, F 统计量为:

$$\frac{\frac{SSE_R - SSE_F}{1}}{\frac{SSE_F}{n-k-1}} = \frac{\frac{b_i^2}{(X^T X)_{[i+1, i+1]}^{-1}}}{s^2} \stackrel{H_0}{\sim} F_{1, n-k-1}$$

其中 $s^2 = \frac{SSE_F}{n-k-1}$ 是残差均方。

与 t 检验的等价性:

注意到 $F_{1, n-k-1} = t_{n-k-1}^2$, 因此该 F 统计量等价于单个回归系数显著性检验的 t 统计量的平方, 即:

$$\frac{b_i^2}{s^2 (X^T X)_{[i+1, i+1]}^{-1}} = t_{n-k-1}^2$$

例 2: 多个回归系数的联合显著性检验

模型与假设:

模型形式: $Y = X\beta + \varepsilon = \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k + \varepsilon$, 其中 $\varepsilon \sim N(0, \sigma^2 I_n)$ 。

原假设: $H_0: \beta_1 = \beta_2 = 0$, 等价于约束矩阵

$$C = \begin{bmatrix} 0, 1, 0, \dots, 0 \\ 0, 0, 1, \dots, 0 \end{bmatrix}$$

满足 $C\beta = \begin{bmatrix} \beta_1 \\ \beta_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$, 约束个数 $m = 2$ 。

平方和差异与 F 统计量:

平方和差异为 $SSE_R - SSE_F = (Cb)^T [C(X^T X)^{-1} C^T]^{-1} Cb$, 其中 $Cb = \begin{bmatrix} b_1 \\ b_2 \end{bmatrix}$ (b_1, b_2 分别为 β_1, β_2 的估计值)。

构造 F 统计量:

$$\frac{\frac{SSE_R - SSE_F}{2}}{\frac{SSE_F}{n-k-1}} \stackrel{H_0}{\sim} F_{2, n-k-1}$$

全模型与约简模型的平方和定义:

- 全模型残差平方和: $SSE_F = Y^T (I - H)Y$, 其中投影矩阵 $H = X(X^T X)^{-1} X^T$, $X \triangleq (\mathbf{1}_n, x_1, \dots, x_k)$ (含截距项的设计矩阵)。
- 约简模型 (不含 x_1, x_2) 残差平方和: SSE_R 是该模型的残差平方和, 平方和差异 $SSE_R -$

SSE_F 反映了 x_1, x_2 对 Y 变异的联合解释能力。