

# 2025 期中

## 题目一

简述用AIC,  $C_p$ 方法对线性回归模型的选择过程

$C_p$  公式:

$$C_p \triangleq \frac{SSE(p)}{s^2} - [n - 2(p + 1)]$$

$C_p$  本质上用

$$C_p \approx p + 1$$

来判断模型是否既不过度拟合也不过度简化。

$AIC \triangleq \max \text{loglikelihood}(k) - k$  ( $k$  为模型中待估参数的数量)

- 概率密度函数 (pdf) :

$$f(Y) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp \left\{ -\frac{1}{2\sigma^2} \|Y - X_p\beta_p\|_2^2 \right\}$$

- 对数似然函数:

$$\text{loglikelihood} = -\frac{1}{2\sigma^2} \|Y - X_p\beta_p\|_2^2 - \frac{n}{2} \log 2\pi - \frac{n}{2} \log \sigma^2$$

- 回归系数的MLE:  $\hat{\beta}_p = (X_p^T X_p)^{-1} X_p^T Y$
- 方差的MLE:  $\hat{\sigma}_{\text{MLE}}^2 = \frac{1}{n} \|Y - X_p\hat{\beta}_p\|_2^2 = \frac{SSE(p)}{n}$

将MLE代入对数似然，整理得：

$$\max \text{loglikelihood} = -\frac{n}{2} - \frac{n}{2} \log 2\pi - \frac{n}{2} \log SSE(p) + \frac{n}{2} \log n$$

根据AIC定义  $AIC \triangleq \max \text{loglikelihood} - k$  (此处  $k = p + 1$ , 即  $\beta_p$  的维度 + 方差参数), 代入并化简 (消去与变量子集无关的常数项后) :

$$\text{AIC} \triangleq -\frac{n}{2} \log SSE(p) - p$$

**应用：**寻找使AIC最大的变量子集  $X_p$ , 以此平衡模型拟合度与复杂度。

## 题目二

已知线性模型  $Y = X\beta + \varepsilon$ ,  $\hat{\beta}$  是  $\beta$  的极大似然估计 (MLE), 满足:

$$P \left( \max_c \frac{|\mathbf{c}'(\hat{\beta} - \beta)|^2}{\mathbf{c}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{c}} \geq M_\alpha \right) = \alpha$$

(其中  $c$  为任意非零向量) (hint: 利用柯西施瓦茨 (Cauchy-Schwarz) 定理) 求  $M_\alpha$ 。

对矩阵  $\mathbf{X}'\mathbf{X}$  做谱分解 (实对称矩阵可正交对角化) :

$$\mathbf{X}'\mathbf{X} = \mathbf{U}\mathbf{D}\mathbf{U}'$$

其中  $\mathbf{U}$  是正交矩阵 ( $\mathbf{U}'\mathbf{U} = \mathbf{I}$ ),  $\mathbf{D}$  是对角矩阵 (对角线为  $\mathbf{X}'\mathbf{X}$  的特征值)。

由此,  $(\mathbf{X}'\mathbf{X})^{-1} = \mathbf{U}\mathbf{D}^{-1}\mathbf{U}'$ , 因此:

$$\mathbf{c}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{c} = \mathbf{c}'\mathbf{U}\mathbf{D}^{-1}\mathbf{U}'\mathbf{c}$$

令  $\mathbf{v} = \mathbf{D}^{-1/2}\mathbf{U}'\mathbf{c}$  (即  $\mathbf{D}^{1/2}\mathbf{v} = \mathbf{U}'\mathbf{c}$ ) , 则上式可改写为:

$$\mathbf{c}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{c} = \mathbf{v}'\mathbf{v}$$

原分式的分子为  $|\mathbf{c}'(\hat{\beta} - \beta)|^2 = [\mathbf{c}'(\hat{\beta} - \beta)]^2$ , 代入  $\mathbf{c} = \mathbf{U}\mathbf{D}^{1/2}\mathbf{v}$  得:

$$[\mathbf{c}'(\hat{\beta} - \beta)]^2 = [\mathbf{v}'\mathbf{D}^{1/2}\mathbf{U}'(\hat{\beta} - \beta)]^2$$

因此, 原分式可表示为:

$$\frac{[\mathbf{v}'\mathbf{D}^{1/2}\mathbf{U}'(\hat{\beta} - \beta)]^2}{s^2\mathbf{v}'\mathbf{v}}$$

根据柯西施瓦茨定理: 对任意向量  $\mathbf{a}, \mathbf{b}$ , 有  $|\mathbf{a}'\mathbf{b}| \leq \|\mathbf{a}\| \cdot \|\mathbf{b}\|$ 。

令  $\mathbf{a} = \mathbf{v}$ ,  $\mathbf{b} = \mathbf{D}^{1/2}\mathbf{U}'(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})$ , 则:

$$|\mathbf{v}'\mathbf{D}^{1/2}\mathbf{U}'(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})| \leq \|\mathbf{v}\| \cdot \|\mathbf{D}^{1/2}\mathbf{U}'(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})\|$$

两边平方后除以  $\mathbf{v}'\mathbf{v} = \|\mathbf{v}\|^2$ , 得:

$$\frac{[\mathbf{v}'\mathbf{D}^{1/2}\mathbf{U}'(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})]^2}{\mathbf{v}'\mathbf{v}} \leq \|\mathbf{D}^{1/2}\mathbf{U}'(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})\|^2$$

因此, 原分式满足:

$$\frac{[\mathbf{c}'(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})]^2}{s^2\mathbf{c}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{c}} \leq \frac{\|\mathbf{D}^{1/2}\mathbf{U}'(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})\|^2}{s^2}$$

已知  $\hat{\boldsymbol{\beta}}$  是 MLE, 其分布为:

$$\hat{\boldsymbol{\beta}} - \boldsymbol{\beta} \sim \mathcal{N}(\mathbf{0}, \sigma^2(\mathbf{X}'\mathbf{X})^{-1})$$

构造统计量  $\frac{1}{\sigma}(\mathbf{X}'\mathbf{X})^{1/2}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})$ , 其中  $(\mathbf{X}'\mathbf{X})^{1/2} = \mathbf{U}\mathbf{D}^{1/2}\mathbf{U}'$ , 易知:

$$\frac{1}{\sigma}(\mathbf{X}'\mathbf{X})^{1/2}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}) \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$

因此, 该统计量的平方范数服从卡方分布:

$$\left\| \frac{1}{\sigma}(\mathbf{X}'\mathbf{X})^{1/2}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}) \right\|^2 = \frac{(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})'\mathbf{X}'\mathbf{X}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})}{\sigma^2} \sim \chi_{k+1}^2$$

(注:  $k + 1$  是  $\boldsymbol{\beta}$  的维度, 即自变量个数+截距项)

记残差方差  $s^2 = \frac{\text{SSE}}{n-(k+1)}$ , 其中  $\text{SSE} \sim \sigma^2\chi_{n-(k+1)}^2$ , 因此  $\frac{(n-(k+1))s^2}{\sigma^2} \sim \chi_{n-(k+1)}^2$ .

构造F统计量 (卡方变量除以自由度后相除) :

$$\frac{\frac{(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})'\mathbf{X}'\mathbf{X}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})}{\sigma^2(k+1)}}{\frac{(n-(k+1))s^2}{\sigma^2(n-(k+1))}} = \frac{(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})'\mathbf{X}'\mathbf{X}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})}{s^2(k+1)} \sim F_{k+1, n-(k+1)}$$

结合步骤3的不等式, 原分式的最大值满足:

$$\max_{\mathbf{c}} \frac{|\mathbf{c}'(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})|^2}{s^2 \mathbf{c}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{c}} \leq \frac{(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})'\mathbf{X}'\mathbf{X}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})}{s^2}$$

而由F分布的分位数定义,  $P\left(\frac{(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})'\mathbf{X}'\mathbf{X}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})}{s^2(k+1)} \geq F_{\alpha;k+1,n-(k+1)}\right) = \alpha$ , 即:

$$P\left(\frac{(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})'\mathbf{X}'\mathbf{X}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})}{s^2} \geq (k+1)F_{\alpha;k+1,n-(k+1)}\right) = \alpha$$

因此, 最终得到:

$$M_\alpha = (k+1)F_{\alpha;k+1,n-(k+1)}$$

### 题目三

3、Model:  $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$ ,  $\hat{\boldsymbol{\beta}} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{Y}$ , 记少了第*i*次观测后得到的 $\hat{\boldsymbol{\beta}}_{(i)}$ , 已知:  $\mathbf{H}$ ,  $\mathbf{x}_i$ ,  $R_i$ ,  $R_i = y_i - \hat{y}_i$

- 1) 请用 $\mathbf{H}$ ,  $\mathbf{x}_i$ ,  $X$ ,  $R_i$ 给出 $\hat{\boldsymbol{\beta}}_{(i)} - \hat{\boldsymbol{\beta}}$ 的表示形式
  - 2) 求 $\frac{1}{n} \sum_{i=1}^n (y_i - \mathbf{x}_i^T \hat{\boldsymbol{\beta}}_{(i)})^2$
- 

### 已知条件

- 原线性模型:  $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$ , 原参数估计为  $\hat{\boldsymbol{\beta}} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{Y}$ ;
- 删去第*i*次观测后, 设计矩阵为 $\mathbf{X}_{(i)}$  (保留 $n-1$ 次观测)、响应向量为 $\mathbf{Y}_{(i)}$ , 对应参数估计为  $\hat{\boldsymbol{\beta}}_{(i)} = (\mathbf{X}_{(i)}^T\mathbf{X}_{(i)})^{-1}\mathbf{X}_{(i)}^T\mathbf{Y}_{(i)}$ ;
- 残差:  $R_i = y_i - \hat{y}_i = y_i - \mathbf{x}_i^T \hat{\boldsymbol{\beta}}$ ;
- 帽子矩阵  $\mathbf{H} = \mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T$ , 其对角线元素  $H_{ii} = \mathbf{x}_i^T(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{x}_i$ .

### $\hat{\boldsymbol{\beta}}_{(i)} - \hat{\boldsymbol{\beta}}$ 的表示形式

矩阵逆的差满足:  $\mathbf{A}^{-1} - \mathbf{B}^{-1} = -\mathbf{A}^{-1}(\mathbf{A} - \mathbf{B})\mathbf{B}^{-1}$ 。

令  $\mathbf{A} = \mathbf{X}_{(i)}^T\mathbf{X}_{(i)}$ ,  $\mathbf{B} = \mathbf{X}^T\mathbf{X}$ , 则:

$$(\mathbf{X}_{(i)}^T \mathbf{X}_{(i)})^{-1} - (\mathbf{X}^T \mathbf{X})^{-1} = -(\mathbf{X}_{(i)}^T \mathbf{X}_{(i)})^{-1} \left( \mathbf{X}_{(i)}^T \mathbf{X}_{(i)} - \mathbf{X}^T \mathbf{X} \right) (\mathbf{X}^T \mathbf{X})^{-1}$$

由于  $\mathbf{X}$  比  $\mathbf{X}_{(i)}$  多了第  $i$  行  $\mathbf{x}_i^T$ , 因此:

$$\mathbf{X}^T \mathbf{X} = \mathbf{X}_{(i)}^T \mathbf{X}_{(i)} + \mathbf{x}_i \mathbf{x}_i^T$$

移项得:

$$\mathbf{X}_{(i)}^T \mathbf{X}_{(i)} - \mathbf{X}^T \mathbf{X} = -\mathbf{x}_i \mathbf{x}_i^T$$

将  $\mathbf{X}_{(i)}^T \mathbf{X}_{(i)} - \mathbf{X}^T \mathbf{X} = -\mathbf{x}_i \mathbf{x}_i^T$  代入逆的差公式, 得:

$$(\mathbf{X}_{(i)}^T \mathbf{X}_{(i)})^{-1} - (\mathbf{X}^T \mathbf{X})^{-1} = (\mathbf{X}_{(i)}^T \mathbf{X}_{(i)})^{-1} \mathbf{x}_i \mathbf{x}_i^T (\mathbf{X}^T \mathbf{X})^{-1}$$

$\mathbf{X}^T \mathbf{Y}$  可拆分为“第  $i$  次观测的贡献”与“剩余  $n - 1$  次观测的贡献”之和:

$$\mathbf{X}^T \mathbf{Y} = \mathbf{x}_i y_i + \mathbf{X}_{(i)}^T \mathbf{Y}_{(i)}$$

因此:

$$\mathbf{X}_{(i)}^T \mathbf{Y}_{(i)} = \mathbf{X}^T \mathbf{Y} - \mathbf{x}_i y_i$$

对  $[(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_i]$  变形:

由  $\mathbf{X}^T \mathbf{X} = \mathbf{X}_{(i)}^T \mathbf{X}_{(i)} + \mathbf{x}_i \mathbf{x}_i^T$ , 两边左乘  $(\mathbf{X}_{(i)}^T \mathbf{X}_{(i)})^{-1}$ 、右乘  $(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_i$ , 得:

$$(\mathbf{X}_{(i)}^T \mathbf{X}_{(i)})^{-1} \mathbf{x}_i \left( 1 - \mathbf{x}_i^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_i \right) = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_i$$

因此:

$$(\mathbf{X}_{(i)}^T \mathbf{X}_{(i)})^{-1} \mathbf{x}_i = \frac{(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_i}{1 - \mathbf{x}_i^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_i}$$

将  $\mathbf{X}_{(i)}^T \mathbf{Y}_{(i)} = \mathbf{X}^T \mathbf{Y} - \mathbf{x}_i y_i$  代入  $\hat{\beta}_{(i)}$  的定义:

$$\hat{\beta}_{(i)} = \left[ (\mathbf{X}^T \mathbf{X})^{-1} + \frac{(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_i \mathbf{x}_i^T (\mathbf{X}^T \mathbf{X})^{-1}}{1 - \mathbf{x}_i^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_i} \right] (\mathbf{X}^T \mathbf{Y} - \mathbf{x}_i y_i)$$

结合  $\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$ , 展开  $\hat{\beta}_{(i)} - \hat{\beta}$ :

$$\begin{aligned} \hat{\beta}_{(i)} - \hat{\beta} &= \left[ (\mathbf{X}^T \mathbf{X})^{-1} + \frac{(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_i \mathbf{x}_i^T (\mathbf{X}^T \mathbf{X})^{-1}}{1 - \mathbf{x}_i^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_i} \right] (\mathbf{X}^T \mathbf{Y} - \mathbf{x}_i y_i) - \hat{\beta} \\ &= \hat{\beta} + \frac{(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_i \mathbf{x}_i^T \hat{\beta}}{1 - \mathbf{x}_i^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_i} - \frac{(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_i y_i}{1 - \mathbf{x}_i^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_i} - \hat{\beta} \end{aligned}$$

合并分子项 (注意  $R_i = y_i - \mathbf{x}_i^T \hat{\beta}$ , 即  $\mathbf{x}_i^T \hat{\beta} - y_i = -R_i$ ) , 并代入  $H_{ii} = \mathbf{x}_i^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_i$ , 最终化简得:

$$\hat{\beta}_{(i)} - \hat{\beta} = \frac{(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_i R_i}{1 - H_{ii}}$$

计算  $\frac{1}{n} \sum_{i=1}^n (y_i - \mathbf{x}_i^T \hat{\beta}_{(i)})^2$

将  $\hat{\beta}_{(i)} = \hat{\beta} + \frac{(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_i R_i}{1 - H_{ii}}$  代入  $y_i - \mathbf{x}_i^T \hat{\beta}_{(i)}$ :

$$\begin{aligned} y_i - \mathbf{x}_i^T \hat{\beta}_{(i)} &= y_i - \mathbf{x}_i^T \left( \hat{\beta} + \frac{(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_i R_i}{1 - H_{ii}} \right) \\ &= (y_i - \mathbf{x}_i^T \hat{\beta}) - \frac{\mathbf{x}_i^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_i R_i}{1 - H_{ii}} \\ &= R_i - \frac{H_{ii} R_i}{1 - H_{ii}} \\ &= \frac{R_i (1 - H_{ii}) - H_{ii} R_i}{1 - H_{ii}} \\ &= \frac{R_i}{1 - H_{ii}} \end{aligned}$$

因此:

$$(y_i - \mathbf{x}_i^T \hat{\beta}_{(i)})^2 = \frac{R_i^2}{(1 - H_{ii})^2}$$

求和并取平均, 最终结果为:

$$\frac{1}{n} \sum_{i=1}^n (y_i - \mathbf{x}_i^T \hat{\boldsymbol{\beta}}_{(i)})^2 = \frac{1}{n} \sum_{i=1}^n \frac{R_i^2}{(1 - H_{ii})^2}$$

## 题目四

推导 logistic 似然函数的 log likelihood；写出 Ridge 形式下的对数似然函数（即给似然函数加了一个罚因子），并推导其对应的更新公式。

### Logistic 似然函数的 log-likelihood

设 Logistic 回归中，第  $i$  个观测的响应变量  $y_i$ （取值为 0 或 1）服从伯努利分布，其概率为：

$$p_i = P(y_i = 1 | \mathbf{x}_i, \boldsymbol{\beta}) = \frac{\exp\{\mathbf{x}_i^T \boldsymbol{\beta}\}}{1 + \exp\{\mathbf{x}_i^T \boldsymbol{\beta}\}}$$

$$1 - p_i = P(y_i = 0 | \mathbf{x}_i, \boldsymbol{\beta}) = \frac{1}{1 + \exp\{\mathbf{x}_i^T \boldsymbol{\beta}\}}$$

**似然函数：**

独立观测下，样本的似然函数为各观测概率的乘积：

$$L(\boldsymbol{\beta}) = \prod_{i=1}^n [p_i^{y_i} \cdot (1 - p_i)^{1-y_i}]$$

**对数似然函数：**

对似然函数取自然对数（将乘积转化为求和，简化计算）：

$$\begin{aligned} \ell(\boldsymbol{\beta}) &= \log L(\boldsymbol{\beta}) \\ &= \sum_{i=1}^n [y_i \log p_i + (1 - y_i) \log(1 - p_i)] \end{aligned}$$

**代入  $p_i$  化简：**

将  $p_i = \frac{\exp\{\mathbf{x}_i^T \boldsymbol{\beta}\}}{1 + \exp\{\mathbf{x}_i^T \boldsymbol{\beta}\}}$  代入，利用  $\log p_i = \mathbf{x}_i^T \boldsymbol{\beta} - \log(1 + \exp\{\mathbf{x}_i^T \boldsymbol{\beta}\})$ 、 $\log(1 - p_i) = -\log(1 + \exp\{\mathbf{x}_i^T \boldsymbol{\beta}\})$ ，化简得：

$$\begin{aligned}\ell(\beta) &= \sum_{i=1}^n [y_i (\mathbf{x}_i^T \beta - \log(1 + \exp\{\mathbf{x}_i^T \beta\})) + (1 - y_i)(-\log(1 + \exp\{\mathbf{x}_i^T \beta\}))] \\ &= \sum_{i=1}^n [y_i \mathbf{x}_i^T \beta - \log(1 + \exp\{\mathbf{x}_i^T \beta\})]\end{aligned}$$


---

## Ridge 形式下的对数似然与更新公式

Ridge 正则化通过添加  $L_2$  惩罚项控制参数复杂度，适用于 Logistic 回归的过拟合问题。

**Ridge 形式的对数似然函数：**

在原对数似然基础上，添加  $\frac{\lambda}{2} \|\beta\|^2$  ( $\lambda \geq 0$  为正则化参数， $\|\beta\|^2 = \beta^T \beta$  为  $L_2$  范数平方) 的惩罚项，得：

$$\ell(\lambda, \beta) = \sum_{i=1}^n [y_i \mathbf{x}_i^T \beta - \log(1 + \exp\{\mathbf{x}_i^T \beta\})] - \frac{\lambda}{2} \|\beta\|^2$$

**一阶导数（梯度）：**

对  $\ell(\lambda, \beta)$  关于  $\beta$  求导（梯度）：

- 原对数似然部分的导数： $\nabla (\sum_{i=1}^n y_i \mathbf{x}_i^T \beta) = \mathbf{X}^T \mathbf{y}$ ;  $\nabla (-\sum_{i=1}^n \log(1 + \exp\{\mathbf{x}_i^T \beta\})) = -\mathbf{X}^T \mathbf{p}$  (其中  $\mathbf{p} = (p_1, p_2, \dots, p_n)^T$ )。
- 惩罚项的导数： $\nabla (-\frac{\lambda}{2} \|\beta\|^2) = -\lambda \beta$ 。

因此梯度为：

$$\nabla \ell(\lambda, \beta) = \mathbf{X}^T \mathbf{y} - \mathbf{X}^T \mathbf{p} - \lambda \beta$$

**二阶导数（Hessian 矩阵）：**

对梯度继续关于  $\beta$  求导（Hessian 矩阵）：

- 原对数似然部分的二阶导数： $\nabla^2 (-\sum_{i=1}^n \log(1 + \exp\{\mathbf{x}_i^T \beta\})) = -\mathbf{X}^T \mathbf{W} \mathbf{X}$  (其中  $\mathbf{W} = \text{diag}\{p_1(1-p_1), p_2(1-p_2), \dots, p_n(1-p_n)\}$  为对角矩阵)。
- 惩罚项的二阶导数： $\nabla^2 (-\frac{\lambda}{2} \|\beta\|^2) = -\lambda \mathbf{I}$  ( $\mathbf{I}$  为单位矩阵)。

因此 Hessian 矩阵为：

$$\nabla^2 \ell(\lambda, \beta) = -\mathbf{X}^T \mathbf{W} \mathbf{X} - \lambda \mathbf{I}$$

**更新公式 (Newton-Raphson 迭代) :**

Newton-Raphson 法通过“当前参数 - Hessian 逆 × 梯度”更新参数，即：

$$\boldsymbol{\beta}^{(k)} = \boldsymbol{\beta}_0 - [\nabla^2 \ell(\lambda, \boldsymbol{\beta})]^{-1} \cdot \nabla \ell(\lambda, \boldsymbol{\beta})$$

将梯度和 Hessian 代入，注意  $[\nabla^2 \ell(\lambda, \boldsymbol{\beta})]^{-1} = (\mathbf{X}^T \mathbf{W} \mathbf{X} + \lambda \mathbf{I})^{-1}$ ，最终更新公式为：

$$\boldsymbol{\beta}^{(k)} = \boldsymbol{\beta}_0 + (\mathbf{X}^T \mathbf{W} \mathbf{X} + \lambda \mathbf{I})^{-1} (\mathbf{X}^T \mathbf{y} - \mathbf{X}^T \mathbf{p}_0 - \lambda \boldsymbol{\beta}_0)$$

(注： $\boldsymbol{\beta}_0$  为迭代初始值， $\mathbf{p}_0$ 、 $\mathbf{W}$  均基于  $\boldsymbol{\beta}_0$  计算)

## 题目五

给定线性模型  $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ ，原假设  $H_0 : \mathbf{A}\boldsymbol{\beta} = \mathbf{c}$ ，似然比定义为：

$$\lambda = \frac{\max_{H_0} L(\boldsymbol{\beta}_0, \mathbf{Y})}{\max_{\Omega} L(\boldsymbol{\beta}, \mathbf{Y})} \quad (\text{likelihood ratio})$$

其中  $\Omega$  为  $\boldsymbol{\beta}$  的无约束参数空间。求：

- 1) 求  $H_0$  下的  $\max_{H_0} L(\boldsymbol{\beta}_0, \mathbf{Y})$ ；
- 2) 求似然比  $\lambda$  的表示形式；
- 3) 求  $-2 \log \lambda$  的渐近分布 ( $n \rightarrow \infty$ )。

### 1) 求 $H_0$ 下的 $\max_{H_0} L(\boldsymbol{\beta}_0, \mathbf{Y})$

在  $H_0 : \mathbf{A}\boldsymbol{\beta} = \mathbf{c}$  下，最大化似然函数等价于最小化残差平方和  $(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^T (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})$  (似然函数的指数部分)。构造拉格朗日函数：

$$\mathcal{L}(\boldsymbol{\beta}, \boldsymbol{\lambda}) = (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^T (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) + \boldsymbol{\lambda}^T (\mathbf{A}\boldsymbol{\beta} - \mathbf{c})$$

其中  $\boldsymbol{\lambda}$  为拉格朗日乘子。

对  $\boldsymbol{\beta}$  求导并令其为0：

$$\frac{\partial \mathcal{L}}{\partial \beta} = -2\mathbf{X}^T(\mathbf{Y} - \mathbf{X}\beta) + \mathbf{A}^T\lambda = \mathbf{0} \implies 2\mathbf{X}^T\mathbf{X}\beta - 2\mathbf{X}^T\mathbf{Y} + \mathbf{A}^T\lambda = \mathbf{0} \quad (1)$$

约束条件:  $\mathbf{A}\beta = \mathbf{c}$

记无约束下的OLS估计为  $\hat{\beta} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{Y}$ , 将  $\mathbf{X}^T\mathbf{Y} = \mathbf{X}^T\mathbf{X}\hat{\beta}$  代入式(1):

$$\beta = \hat{\beta} - \frac{1}{2}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{A}^T\lambda$$

代入约束条件(2):

$$\mathbf{A}\hat{\beta} - \frac{1}{2}\mathbf{A}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{A}^T\lambda = \mathbf{c}$$

解得拉格朗日乘子:

$$\lambda = 2 \left[ \mathbf{A}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{A}^T \right]^{-1} (\mathbf{A}\hat{\beta} - \mathbf{c})$$

将  $\lambda$  代回  $\beta$  的表达式, 得  $H_0$  下的约束估计:

$$\hat{\beta}_0 = \hat{\beta} - (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{A}^T \left[ \mathbf{A}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{A}^T \right]^{-1} (\mathbf{A}\hat{\beta} - \mathbf{c})$$

在  $H_0$  下,  $\sigma^2$  的极大似然估计为:

$$\hat{\sigma}_0^2 = \frac{1}{n}(\mathbf{Y} - \mathbf{X}\hat{\beta}_0)^T(\mathbf{Y} - \mathbf{X}\hat{\beta}_0)$$

将  $\hat{\beta}_0$  和  $\hat{\sigma}_0^2$  代入似然函数, 得  $H_0$  下的最大似然:

$$\max_{H_0} L(\beta_0, \mathbf{Y}) = \frac{1}{(2\pi\hat{\sigma}_0^2)^{n/2}} \exp \left\{ -\frac{n}{2} \right\}$$

## 2) 求似然比 $\lambda$ 的表示形式

无约束下的最大似然 ( $\Omega$  下) :

$$\max_{\Omega} L(\boldsymbol{\beta}, \mathbf{Y}) = \frac{1}{(2\pi\hat{\sigma}^2)^{n/2}} \exp \left\{ -\frac{n}{2} \right\}$$

其中  $\hat{\sigma}^2 = \frac{1}{n}(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}})^T(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}})$  为无约束下  $\sigma^2$  的极大似然估计。

似然比定义为“约束最大似然 / 无约束最大似然”，代入得：

$$\lambda = \frac{\max_{H_0} L}{\max_{\Omega} L} = \left( \frac{\hat{\sigma}^2}{\hat{\sigma}_0^2} \right)^{n/2}$$

-----

### 3) 求 $-2 \log \lambda$ 的渐近分布 ( $n \rightarrow \infty$ )

由  $\lambda = \left( \frac{\hat{\sigma}^2}{\hat{\sigma}_0^2} \right)^{n/2}$ , 取对数得：

$$-2 \log \lambda = n \log \left( \frac{\hat{\sigma}_0^2}{\hat{\sigma}^2} \right)$$

由约束估计的性质，约束残差平方和与无约束残差平方和满足：

$$(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}_0)^T(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}_0) = (\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}})^T(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}) + (\mathbf{A}\hat{\boldsymbol{\beta}} - \mathbf{c})^T [\mathbf{A}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{A}^T]^{-1} (\mathbf{A}\hat{\boldsymbol{\beta}} - \mathbf{c})$$

因此：

$$\frac{\hat{\sigma}_0^2}{\hat{\sigma}^2} = 1 + \frac{(\mathbf{A}\hat{\boldsymbol{\beta}} - \mathbf{c})^T [\mathbf{A}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{A}^T]^{-1} (\mathbf{A}\hat{\boldsymbol{\beta}} - \mathbf{c})}{(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}})^T(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}})}$$

当  $n \rightarrow \infty$  时,  $\frac{(\mathbf{A}\hat{\boldsymbol{\beta}} - \mathbf{c})^T [\mathbf{A}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{A}^T]^{-1} (\mathbf{A}\hat{\boldsymbol{\beta}} - \mathbf{c})}{(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}})^T(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}})} \rightarrow 0$ , 利用近似  $\log(1 + x) \approx x$  ( $x \rightarrow 0$ ) , 得：

$$\log \left( \frac{\hat{\sigma}_0^2}{\hat{\sigma}^2} \right) \approx \frac{(\mathbf{A}\hat{\boldsymbol{\beta}} - \mathbf{c})^T [\mathbf{A}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{A}^T]^{-1} (\mathbf{A}\hat{\boldsymbol{\beta}} - \mathbf{c})}{(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}})^T(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}})}$$

由无约束估计的渐近性质:  $\hat{\beta} \sim N_p \left( \beta, \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1} \right)$ , 因此:

$$\mathbf{A}\hat{\beta} - \mathbf{c} \sim N_m \left( \mathbf{0}, \sigma^2 \mathbf{A}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{A}^T \right) \quad (\text{若 } H_0 \text{ 成立})$$

进而:

$$(\mathbf{A}\hat{\beta} - \mathbf{c})^T \left[ \sigma^2 \mathbf{A}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{A}^T \right]^{-1} (\mathbf{A}\hat{\beta} - \mathbf{c}) \sim \chi^2(m)$$

同时,  $\frac{1}{\sigma^2 n} (\mathbf{Y} - \mathbf{X}\hat{\beta})^T (\mathbf{Y} - \mathbf{X}\hat{\beta}) \xrightarrow{P} 1$  (依概率收敛), 因此:

$$-2 \log \lambda \xrightarrow{d} \chi^2(m) \quad (n \rightarrow \infty)$$

最终结论: 当  $n \rightarrow \infty$  时,  $-2 \log \lambda$  渐近服从自由度为  $m$  的卡方分布  $\chi^2(m)$ .